

ĐỒ ÁN/ KHÓA LUẬN TỐT NGHIỆP

XÂY DỰNG MÔ HÌNH PHÁT HIỆN HÀNH VI BẠO LỰC HỌC ĐƯỜNG THEO THỜI GIAN THỰC DỰA TRÊN PHÂN TÍCH VIDEO GIÁM SÁT

Ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS. Nguyễn Quang Phúc

Sinh viên thực hiện : Trương Minh Khoa

MSSV: 2286400011 Lớp: 22DKHA1

TP. Hồ Chí Minh, 2026

ĐỒ ÁN/ KHÓA LUẬN TỐT NGHIỆP**XÂY DỰNG MÔ HÌNH PHÁT HIỆN HÀNH VI
BẠO LỰC HỌC ĐƯỜNG THEO THỜI GIAN
THỰC DỰA TRÊN PHÂN TÍCH VIDEO GIÁM
SÁT**Ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS. Nguyễn Quang Phúc

Sinh viên thực hiện : Trương Minh Khoa

MSSV: 2286400011 Lớp: 22DKHA1

Giảng viên hướng dẫn	Giảng viên phản biện	Chủ tịch hội đồng

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP.HCM, Ngày Tháng Năm 2026

Giáo viên hướng dẫn

(Ký tên, đóng dấu)

LỜI CAM ĐOAN

Tôi là **Trương Minh Khoa**, sinh viên lớp **22DKHA1**, ngành **Khoa học Dữ liệu**, Khoa Công nghệ Thông tin, Trường Đại học Công nghệ TP.HCM (HUTECH), xin trân trọng cam đoan những nội dung sau:

Đồ án tốt nghiệp với đề tài “**XÂY DỰNG MÔ HÌNH PHÁT HIỆN HÀNH VI BẠO LỰC HỌC ĐƯỜNG THEO THỜI GIAN THỰC DỰA TRÊN PHÂN TÍCH VIDEO GIÁM SÁT**” là công trình nghiên cứu do chính tôi thực hiện dưới sự hướng dẫn trực tiếp của giảng viên hướng dẫn. Toàn bộ nội dung, số liệu, kết quả và nhận định trong đồ án là trung thực, khách quan và chưa từng được công bố trong bất kỳ công trình nào khác.

Quá trình thực hiện đồ án được tiến hành nghiêm túc, độc lập và có trách nhiệm. Các tài liệu tham khảo, cơ sở dữ liệu, hình ảnh, bảng biểu và kết quả thực nghiệm sử dụng trong đồ án đều được trích dẫn đầy đủ, rõ ràng theo đúng quy định học thuật của Nhà trường.

Tôi cam kết không sao chép, trích dẫn sai lệch hoặc sử dụng trái phép nội dung từ các công trình nghiên cứu của tác giả khác. Đồ án là sản phẩm nghiên cứu độc lập của cá nhân tôi và được thực hiện trong sự tuân thủ các quy định về đạo đức học thuật, quy chế đồ án tốt nghiệp và các quy định liên quan của Trường Đại học Công nghệ TP.HCM.

Tôi hoàn toàn chịu trách nhiệm trước Hội đồng Bảo vệ Đồ án Tốt nghiệp, Khoa Công nghệ Thông tin và Nhà trường về tính xác thực, trung thực và hợp lệ của toàn bộ nội dung trong đồ án. Nếu có bất kỳ gian lận hoặc vi phạm nào, tôi xin hoàn toàn chịu trách nhiệm và chấp nhận mọi hình thức xử lý theo quy định.

TP. Hồ Chí Minh, ngày 19 tháng 4 năm 2026

Sinh viên thực hiện

(Ký và ghi rõ họ tên)

Trương Minh Khoa

MỤC LỤC

DANH MỤC HÌNH ẢNH	7
DANH MỤC ĐỒ THỊ	8
DANH MỤC BẢNG	9
DANH MỤC TỪ VIẾT TẮT	10
1 TỔNG QUAN	11
1.1 Giới thiệu đề tài	11
1.2 Nhiệm vụ của đề tài	12
1.2.1 Tính cấp thiết của đề tài	12
1.2.2 Ý nghĩa khoa học và thực tiễn	13
1.3 Mục tiêu của đề tài	14
1.3.1 Mục tiêu tổng quát	14
1.3.2 Mục tiêu cụ thể	14
1.4 Đối tượng và phạm vi nghiên cứu	15
1.5 Những đóng góp của đề tài	15
1.6 Cấu trúc đồ án	16
2 CÔNG TRÌNH LIÊN QUAN	18
2.1 Tổng quan lĩnh vực phát hiện bạo lực trong video	18
2.2 Nhóm 1: Tiếp cận CNN + RNN/LSTM trên toàn video	19
2.3 Nhóm 2: Tiếp cận 3D CNN (C3D, I3D, SlowFast)	20
2.4 Nhóm 3: Tiếp cận dựa trên YOLO Detection + Tracking	20
2.5 Nhóm 4: Tiếp cận Two-stream và Optical Flow	22
2.6 Nhóm 5: Tiếp cận Transformer và Attention	22
2.7 Tổng hợp và phân tích khoảng trống nghiên cứu	24
2.8 Định hướng nghiên cứu của đề tài	25
3 KIẾN TRÚC ĐỀ XUẤT	27
3.1 Pipeline tổng quan hệ thống	27
3.2 Bước 1: Thu thập dữ liệu từ camera	28
3.3 Bước 2: Tiền xử lý và chuẩn hóa dữ liệu	29
3.4 Bước 3: Phát hiện đối tượng và trích xuất đặc trưng	30
3.4.1 YOLO11s + ByteTrack – Phát hiện và tracking người	30
3.4.2 Spatial CNN – Trích xuất đặc trưng không gian	31

3.4.3	Multi-scale Temporal Conv1D – Phân tích chuyển động	31
3.5	Bước 4: Phân loại hành vi bạo lực / bình thường	32
3.5.1	Bi-LSTM – Phân tích chuỗi thời gian hai chiều	32
3.5.2	Temporal Attention – Tập trung khoảng khắc quyết định	32
3.5.3	FC Classifier và ngưỡng phân loại	33
3.6	Bước 5: Phát hiện và cảnh báo thời gian thực	33
3.6.1	Logic kết luận đa tầng	33
3.6.2	Hệ thống cảnh báo và ứng dụng SafeWatch	35
3.7	Tổng kết kiến trúc và mối liên hệ với khoảng trống	36
4	THỰC NGHIỆM	39
4.1	Bộ dữ liệu (Dataset)	39
4.1.1	Nguồn gốc và cách thu thập	39
4.1.2	Cấu trúc và thống kê	39
4.1.3	Quy trình gán nhãn (Annotation)	41
4.2	Phương pháp đánh giá	41
4.3	Cấu hình thực nghiệm (Setting)	42
4.3.1	Phần cứng và nền tảng	42
4.3.2	Siêu tham số (Hyperparameters)	44
4.4	Kết quả thực nghiệm	45
4.4.1	Kết quả xây dựng bộ dữ liệu	45
4.4.2	Diễn tiến huấn luyện (Loss & Accuracy)	45
4.4.3	Đánh giá trên tập Validation	46
4.4.4	Đánh giá trên tập Test	47
4.4.5	So sánh với các kiến trúc khác (Ablation Study)	50
4.4.6	Thảo luận kết quả	50
	KẾT LUẬN	52

DANH MỤC HÌNH ẢNH

1	Ví dụ về các tình huống bạo lực học đường được ghi lại qua hệ thống camera giám sát	12
2	Sơ đồ tổng quan pipeline 5 bước của hệ thống phát hiện bạo lực học đường	27
3	Ví dụ frame mẫu về tình huống bạo lực trong bối cảnh trường học	28
4	Sơ đồ logic xử lý và cảnh báo của hệ thống SafeWatch	34
5	Giao diện menu điều hướng và dashboard tổng quan của SafeWatch App	35
6	Cảnh báo gửi tới Gmail và Telegram khi hệ thống phát hiện video có dấu hiệu bạo lực	35
7	Kiến trúc tổng thể mô hình ImprovedViolenceModel trong pipeline huấn luyện	37

DANH MỤC ĐỒ THỊ

1	Biểu đồ phân phối dữ liệu train/validation/test	41
2	Đường cong Loss trên tập huấn luyện và tập kiểm định theo epoch	46
3	Đường cong Accuracy trên tập huấn luyện và tập kiểm định theo epoch .	46
4	Heatmap ma trận nhầm lẫn trên tập Validation	47
5	Heatmap ma trận nhầm lẫn trên tập Test	48
6	Phân phối xác suất bạo lực trên tập Validation	49
7	Phân phối xác suất bạo lực trên tập Test	49

DANH MỤC BẢNG

2	Timeline phát triển các phương pháp phát hiện bạo lực trong video	18
3	Tổng hợp 15 công trình nghiên cứu liên quan	23
4	Phân tích khoảng trống nghiên cứu	24
5	Tóm tắt các khoảng trống nghiên cứu chính	25
6	Các bước chuẩn hóa dữ liệu trong pipeline tiền xử lý	29
7	Tham số cấu hình YOLO11s tracking	31
8	Đối chiếu mỗi bước pipeline với khoảng trống nghiên cứu	36
9	Kiến trúc chi tiết mô hình ImprovedViolenceModel	37
10	Thông tin thống kê bộ dữ liệu tự xây dựng	40
11	Thống kê tổng hợp bộ dữ liệu sau tiền xử lý	40
12	Cấu hình phần cứng và nền tảng thực nghiệm	43
13	Tổng hợp siêu tham số huấn luyện	44
14	Các kỹ thuật Data Augmentation áp dụng	44
15	Kết quả đánh giá mô hình trên tập Validation	47
16	Kết quả đánh giá mô hình trên tập Test độc lập	48
17	So sánh hiệu quả với các kiến trúc tham khảo	50

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa
AI	Artificial Intelligence – Trí tuệ nhân tạo
API	Application Programming Interface – Giao diện lập trình ứng dụng
Bi-LSTM	Bidirectional Long Short-Term Memory – Mạng LSTM hai chiều
CNN	Convolutional Neural Network – Mạng nơ-ron tích chập
CVAT	Computer Vision Annotation Tool – Công cụ gán nhãn dữ liệu thị giác máy tính
DATN	Đồ án tốt nghiệp
DL	Deep Learning – Học sâu
FPS	Frames Per Second – Số khung hình trên giây
GPU	Graphics Processing Unit – Bộ xử lý đồ họa
HOG	Histogram of Oriented Gradients
IoU	Intersection over Union – Độ giao nhau trên hợp nhất
LSTM	Long Short-Term Memory – Mạng bộ nhớ ngắn hạn dài
MOT	Multi-Object Tracking – Theo dõi đa đối tượng
REST	Representational State Transfer
RGB	Red Green Blue – Hệ màu đỏ, xanh lá, xanh dương
SSL	Secure Sockets Layer
SVM	Support Vector Machine – Máy véc-tơ hỗ trợ
YOLO	You Only Look Once – Họ mô hình phát hiện đối tượng thời gian thực

CHƯƠNG 1. TỔNG QUAN

1.1 Giới thiệu đề tài

Bạo lực học đường là một vấn đề xã hội nghiêm trọng tại Việt Nam và nhiều quốc gia trên thế giới. Các hành vi như đánh nhau, xô đẩy, đui đánh hoặc vật lộn không chỉ gây tổn hại về thể chất, mà còn ảnh hưởng lâu dài đến tâm lý, kết quả học tập và cảm giác an toàn của học sinh trong môi trường giáo dục. Vì vậy, việc phát hiện sớm và hỗ trợ can thiệp kịp thời các tình huống bạo lực là nhu cầu có ý nghĩa thực tiễn rõ ràng.

Hiện nay, nhiều trường học đã lắp đặt camera tại cổng trường, hành lang, sân trường, lớp học và một số khu vực công cộng. Tuy nhiên, phần lớn hệ thống camera vẫn hoạt động theo hướng ghi hình thụ động. Video thường chỉ được xem lại sau khi sự việc đã xảy ra, phục vụ xác minh hoặc xử lý hậu quả. Cách làm này chưa đủ để hỗ trợ cảnh báo sớm, đặc biệt với các tình huống bạo lực diễn ra nhanh trong vài giây.

Việc giám sát thủ công cũng có nhiều giới hạn. Nhân viên bảo vệ hoặc cán bộ quản lý khó có thể theo dõi liên tục hàng chục camera trong thời gian dài. Khi số lượng màn hình tăng lên, khả năng bỏ sót tình huống bất thường cũng tăng theo. Do đó, một hệ thống giám sát thông minh có khả năng tự động phân tích video và phát hiện dấu hiệu bạo lực theo thời gian gần thực là hướng nghiên cứu cần thiết.

Sự phát triển mạnh mẽ của Deep Learning và Computer Vision trong những năm gần đây đã mở ra khả năng xây dựng các hệ thống như vậy. Các mô hình phát hiện đối tượng có thể xác định vị trí con người trong khung hình, thuật toán tracking có thể theo dõi từng người qua nhiều frame, còn mô hình nhận diện hành động có thể phân tích chuỗi chuyển động để phân loại hành vi. Đây là nền tảng kỹ thuật quan trọng cho bài toán phát hiện bạo lực học đường từ video camera.

Từ bối cảnh trên, đề tài đề xuất một pipeline end-to-end cho bài toán phát hiện hành vi bạo lực trong trường học. Pipeline gồm năm bước chính: thu thập dữ liệu video, tiền xử lý và chuẩn hóa dữ liệu, phát hiện và theo dõi người, phân loại hành vi bạo lực, sau đó tổng hợp kết quả và phát cảnh báo. Hướng tiếp cận này giúp kết nối từ dữ liệu đầu vào đến kết quả đầu ra thành một quy trình hoàn chỉnh, thay vì chỉ dừng ở việc huấn luyện một mô hình đơn lẻ.

Về kỹ thuật, hệ thống kết hợp **YOLO11s** để phát hiện người, **ByteTrack** để theo dõi đa đối tượng và mô hình phân loại hành vi được thiết kế theo chuỗi **Spatial CNN – Multi-scale Temporal Conv1D – Bi-LSTM – Temporal Attention – Fully Connected Classifier**. Trong đó, Spatial CNN trích xuất đặc trưng không gian từ từng crop người, Multi-scale Temporal Conv1D học chuyển động ở nhiều tỉ lệ thời gian, Bi-LSTM khai thác ngữ cảnh hai chiều và Attention giúp mô hình tập trung vào các frame quan trọng.

Điểm khác biệt của đề tài là hướng phân tích *per-track*. Thay vì phân loại toàn bộ video như một cảnh duy nhất, hệ thống tách từng người thành một track riêng và phân

tích hành vi trên chuỗi frame của track đó. Cách làm này phù hợp với môi trường trường học, nơi một khung hình có thể xuất hiện nhiều học sinh nhưng chỉ một nhóm nhỏ liên quan trực tiếp đến hành vi bạo lực. Nhờ phân tích theo track, mô hình có thể giảm nhiễu từ nền và từ các đối tượng không liên quan.



Hình 1: Ví dụ về các tình huống bạo lực học đường được ghi lại qua hệ thống camera giám sát

1.2 Nhiệm vụ của đề tài

1.2.1 Tính cấp thiết của đề tài

Tính cấp thiết của đề tài xuất phát từ nhu cầu đảm bảo an toàn trong môi trường học đường. Khi một vụ bạo lực xảy ra, thời gian phản ứng có vai trò rất quan trọng. Nếu sự việc chỉ được phát hiện sau khi đã có hậu quả rõ ràng, khả năng can thiệp và hạn chế thiệt hại sẽ giảm đi đáng kể. Vì vậy, hệ thống có khả năng phát hiện sớm và hỗ trợ cảnh báo tự động là cần thiết.

Các hệ thống camera truyền thống chưa giải quyết tốt yêu cầu này vì chủ yếu ghi hình để xem lại. Trong khi đó, nhân viên bảo vệ không thể quan sát liên tục nhiều camera cùng lúc, đặc biệt trong giờ ra chơi, giờ tan học hoặc các thời điểm có mật độ học sinh cao. Một tình huống xô xát có thể xuất hiện nhanh, bị che khuất một phần hoặc chỉ xảy ra ở một vùng nhỏ trong khung hình, khiến việc theo dõi thủ công dễ bỏ sót.

Bên cạnh nhu cầu thực tế, Deep Learning đã chứng minh hiệu quả cao trong các bài toán nhận diện hành động từ video. Các kiến trúc kết hợp CNN, LSTM và Attention có khả năng khai thác đồng thời đặc trưng không gian và thời gian, phù hợp với bản chất của hành vi bạo lực. Tuy nhiên, nhiều nghiên cứu vẫn tập trung vào các bộ dữ liệu nước

ngoài như Hockey Fight, UCF-Crime hoặc RWF-2000, trong khi dữ liệu phù hợp với bối cảnh trường học Việt Nam còn hạn chế.

Ngoài ra, các giải pháp thương mại hiện có thường yêu cầu chi phí triển khai cao hoặc phụ thuộc vào phần cứng mạnh. Điều này chưa thật sự phù hợp với nhiều trường học. Vì vậy, đề tài lựa chọn hướng xây dựng một pipeline có tính cân bằng: có khả năng phát hiện hành vi bạo lực, có thể kiểm thử trên dữ liệu tự xây dựng và hướng đến triển khai trên cấu hình phần cứng phổ thông.

1.2.2 Ý nghĩa khoa học và thực tiễn

Về mặt khoa học, đề tài đề xuất và kiểm thử kiến trúc kết hợp nhiều thành phần gồm **Spatial CNN**, **Multi-scale Temporal Conv1D**, **Bi-LSTM** và **Temporal Attention**. Sự kết hợp này nhằm khắc phục hạn chế của từng thành phần đơn lẻ: CNN mạnh về đặc trưng không gian nhưng chưa đủ để hiểu chuyển động; Conv1D học mẫu thời gian cục bộ; Bi-LSTM bổ sung ngữ cảnh trước-sau; Attention giúp tập trung vào các thời điểm có dấu hiệu bạo lực rõ nhất.

Đề tài cũng nghiên cứu hướng phân tích theo từng track người thay vì phân loại toàn bộ video. Hướng *per-track classification* giúp mô hình tập trung vào từng đối tượng cụ thể, từ đó giảm ảnh hưởng của nền, đám đông và các học sinh không liên quan. Đây là điểm phù hợp với môi trường camera trường học, nơi cùng một khung hình có thể chứa nhiều hoạt động khác nhau.

Bên cạnh đó, đề tài áp dụng cơ chế quyết định đa tầng. Ở cấp track, hệ thống sử dụng ngưỡng xác suất để xác định track có dấu hiệu bạo lực. Ở cấp video, kết quả từ nhiều track được tổng hợp để đưa ra kết luận cuối cùng. Cơ chế này giúp giảm phụ thuộc vào một dự đoán đơn lẻ và hỗ trợ kiểm soát tỷ lệ cảnh báo nhầm.

Về mặt thực tiễn, hệ thống có thể tích hợp vào camera an ninh trường học để hỗ trợ cảnh báo khi phát hiện hành vi bạo lực. Khi có cảnh báo, nhân viên quản lý có thể kiểm tra lại video, xác định thời điểm nghi vấn và phản ứng nhanh hơn. Điều này giúp giảm tải cho việc giám sát thủ công và tăng khả năng phát hiện sự cố trong môi trường có nhiều camera.

Đề tài cũng phát triển hướng ứng dụng **SafeWatch App** với backend FastAPI và giao diện web Flutter. Ứng dụng hỗ trợ tải video, theo dõi hàng chờ xử lý, hiển thị kết quả phân tích, quan sát timeline cảnh báo và xuất báo cáo. Nhờ đó, kết quả nghiên cứu không chỉ nằm ở mô hình huấn luyện, mà được đặt trong một pipeline có khả năng thao tác và kiểm chứng trực quan.

1.3 Mục tiêu của đề tài

1.3.1 Mục tiêu tổng quát

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống phát hiện hành vi bạo lực trong video trường học một cách tự động, chính xác và hướng đến hoạt động theo thời gian gần thực. Hệ thống dựa trên kiến trúc Deep Learning kết hợp phát hiện/tracking người bằng YOLO11s và ByteTrack với mô hình phân loại hành vi CNN–BiLSTM–Attention tự thiết kế.

Nói cách khác, đề tài hướng đến một quy trình hoàn chỉnh từ video đầu vào đến cảnh báo đầu ra. Hệ thống không chỉ nhận diện người trong video, mà còn theo dõi từng người qua thời gian, tạo chuỗi dữ liệu đầu vào cho mô hình, phân loại hành vi và tổng hợp kết quả ở cấp độ video để hỗ trợ người dùng ra quyết định.

1.3.2 Mục tiêu cụ thể

Để đạt được mục tiêu tổng quát, đề tài triển khai các mục tiêu cụ thể sau:

- Xây dựng và gán nhãn bộ dữ liệu video bạo lực/không bạo lực trong môi trường trường học, gồm **389 video** với annotation theo chuẩn CVAT.
- Ứng dụng **YOLO11s** và **ByteTrack** để tự động phát hiện và tracking từng người trong video.
- Thiết kế pipeline tiền xử lý gồm chuẩn hóa FPS, crop theo bounding box, resize ảnh, normalize pixel và tạo mẫu bằng Sliding Window.
- Đề xuất và triển khai kiến trúc mô hình **Spatial CNN – Multi-scale Temporal Conv1D – Bi-LSTM – Attention – FC**.
- Huấn luyện mô hình với các kỹ thuật nâng cao như MixUp, Focal Loss, Data Augmentation, Label Smoothing, AdamW, Warmup, Cosine Annealing và Early Stopping.
- Đánh giá mô hình trên tập validation và tập test độc lập, với Accuracy đạt khoảng **90%** trên validation và khoảng **89%** trên test trong phạm vi dữ liệu thực nghiệm.
- Xây dựng REST API bằng **FastAPI** để kết nối pipeline AI với giao diện sử dụng.
- Phát triển ứng dụng web **SafeWatch** bằng Flutter Web, hỗ trợ upload video, hàng chờ xử lý, dashboard, timeline cảnh báo và xuất báo cáo.

Các mục tiêu trên được đặt trong phạm vi phù hợp với đồ án tốt nghiệp. Đề tài không hướng đến sản phẩm thương mại hoàn chỉnh ngay lập tức, mà tập trung chứng minh tính khả thi của giải pháp, đánh giá hiệu quả mô hình và chỉ ra các giới hạn cần cải thiện.

1.4 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là video từ camera an ninh trong môi trường trường học, bao gồm các bối cảnh như sân trường, hành lang, lớp học và cổng trường. Hành vi bạo lực được xem xét gồm đánh nhau, xô đẩy, đuổi đánh, vật lộn hoặc các tương tác mạnh có tính đối kháng. Hành vi bình thường gồm đi bộ, đứng, ngồi, nói chuyện, chạy hoặc các hoạt động không mang tính bạo lực.

Phạm vi nghiên cứu được giới hạn như sau:

- Bài toán được mô hình hóa theo hướng phân loại nhị phân: *violence* và *non-violence*.
- Dữ liệu sử dụng gồm **389 video**, trong đó có **189 video violence** và **200 video non-violence**.
- Hệ thống chỉ sử dụng dữ liệu hình ảnh từ video, chưa kết hợp âm thanh, cảm biến chuyển động hoặc dữ liệu văn bản.
- Ngôn ngữ và công nghệ chính gồm Python 3.11+, PyTorch, YOLO, FastAPI, Dart và Flutter Web.
- Quá trình huấn luyện được thực hiện trên Kaggle GPU T100; giai đoạn suy luận hướng đến khả năng chạy trên CPU thông thường.
- Đề tài chưa xử lý bạo lực ngôn từ, bắt nạt trực tuyến hoặc các dạng bạo lực phi thể chất khó nhận biết chỉ từ hình ảnh.
- Phần ứng dụng tập trung vào xử lý video, hiển thị kết quả và hỗ trợ cảnh báo; chưa triển khai đầy đủ các yêu cầu vận hành quy mô lớn như phân quyền nhiều cấp, mã hóa đầu cuối hoặc chính sách lưu trữ dài hạn.

Phạm vi này giúp đề tài giữ được trọng tâm và khả thi trong thời gian thực hiện. Hệ thống được xem là mô hình nghiên cứu và thử nghiệm ban đầu, cần tiếp tục mở rộng dữ liệu, tối ưu tốc độ và kiểm thử thực địa trước khi triển khai rộng rãi.

1.5 Những đóng góp của đề tài

Các đóng góp của đề tài được chia thành hai nhóm: đóng góp về mặt lý thuyết và đóng góp về mặt thực tiễn.

Về mặt lý thuyết, đề tài có các đóng góp sau:

- Đề xuất kiến trúc kết hợp nhiều thành phần: **Spatial CNN**, **Multi-scale Temporal Conv1D**, **Bi-LSTM** và **Temporal Attention** cho bài toán phân loại hành vi bạo lực theo từng track người.

- Đề xuất cơ chế quyết định đa tầng, trong đó kết quả track-level được xác định theo ngưỡng 45% và kết quả video-level dựa trên biến `max_violent_persons`; video được kết luận là bạo lực khi `max_violent_persons` ≥ 1 .
- Phân tích ưu điểm và hạn chế của phương pháp *per-track classification* so với phương pháp phân loại toàn video truyền thống.
- Làm rõ vai trò của đặc trưng không gian, đặc trưng thời gian đa tỉ lệ, ngữ cảnh hai chiều và cơ chế chú ý trong bài toán nhận diện bạo lực từ video.

Về mặt thực tiễn, đề tài có các đóng góp sau:

- Xây dựng bộ dữ liệu gồm **389 video** có annotation theo chuẩn CVAT XML, phù hợp với bối cảnh nghiên cứu phát hiện bạo lực học đường.
- Xây dựng pipeline hoàn chỉnh từ raw video đến annotation, tiền xử lý, training, inference và hiển thị kết quả trên ứng dụng web.
- Tích hợp mô hình vào hướng ứng dụng **SafeWatch App**, hỗ trợ upload video, hàng chờ xử lý, dashboard, timeline cảnh báo, cảnh báo qua email/Telegram và xuất báo cáo PDF.
- Cung cấp kết quả thực nghiệm trên tập validation và test độc lập, làm cơ sở phân tích hiệu quả cũng như các hạn chế của hệ thống.

Từ các đóng góp trên, đề tài cho thấy hướng phát hiện bạo lực học đường bằng video giám sát là khả thi trong phạm vi nghiên cứu của một đồ án tốt nghiệp. Đây là bước nền tảng để tiếp tục mở rộng dữ liệu, cải thiện mô hình và kiểm thử trong môi trường trường học thực tế.

1.6 Cấu trúc đồ án

Đồ án được tổ chức thành bốn chương chính và phần kết luận. Nội dung cụ thể như sau:

- **Chương 1 – Tổng quan:** Trình bày bối cảnh, tính cấp thiết, mục tiêu, đối tượng, phạm vi nghiên cứu, các đóng góp chính và cấu trúc của đồ án.
- **Chương 2 – Công trình liên quan:** Khảo sát và phân tích các nghiên cứu tiêu biểu trong lĩnh vực phát hiện bạo lực bằng video, bao gồm các hướng tiếp cận CNN-LSTM, 3D CNN, YOLO kết hợp tracking, two-stream và Transformer. Từ đó, chương này tổng hợp khoảng trống nghiên cứu và xác định hướng tiếp cận của đề tài.

- **Chương 3 – Kiến trúc đề xuất:** Trình bày pipeline tổng quan gồm thu thập dữ liệu, tiền xử lý, phát hiện và tracking người, trích xuất đặc trưng, phân loại hành vi và cảnh báo. Chương này cũng giải thích lý do lựa chọn từng kỹ thuật, mô tả kiến trúc mô hình ImprovedViolenceModel và cách tích hợp vào SafeWatch App.
- **Chương 4 – Thực nghiệm:** Mô tả bộ dữ liệu, phương pháp đánh giá, cấu hình phần cứng, siêu tham số huấn luyện và các kết quả thực nghiệm. Chương này cũng phân tích confusion matrix, kết quả test độc lập, ablation study và các trường hợp phân loại sai.
- **Kết luận:** Tóm tắt kết quả đạt được, chỉ ra các hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai.

CHƯƠNG 2. CÔNG TRÌNH LIÊN QUAN

2.1 Tổng quan lĩnh vực phát hiện bạo lực trong video

Phát hiện bạo lực trong video (Video Violence Detection) là bài toán phân loại một đoạn video, một chuỗi frame hoặc một hành vi quan sát được trong video thành hai lớp chính: *violence* và *non-violence*. Đây là một bài toán con của lĩnh vực nhận diện hành động (Action Recognition), nhưng có yêu cầu thực tế khắt khe hơn vì liên quan đến cảnh báo an ninh, thời gian phản ứng và nguy cơ bỏ sót sự kiện nguy hiểm.

Khác với phân loại ảnh tĩnh, dữ liệu video chứa đồng thời thông tin không gian và thời gian. Một frame đơn lẻ thường chưa đủ để kết luận có bạo lực hay không. Hệ thống cần quan sát sự thay đổi liên tục của tư thế, vị trí, vận tốc và tương tác giữa các đối tượng. Vì vậy, các nghiên cứu trong lĩnh vực này thường tập trung vào hai câu hỏi chính: trích xuất đặc trưng hình ảnh như thế nào và mô hình hóa chuyển động theo thời gian ra sao.

Trong khoảng hơn mười năm qua, các phương pháp phát hiện bạo lực trong video có thể chia thành ba giai đoạn chính. Giai đoạn đầu, từ khoảng 2011 đến 2016, chủ yếu sử dụng đặc trưng thủ công như HOG, Optical Flow, Bag-of-Words và SVM. Các phương pháp này tương đối nhẹ nhưng phụ thuộc nhiều vào chất lượng đặc trưng được thiết kế. Giai đoạn 2016–2020 chứng kiến sự phát triển của CNN kết hợp RNN/LSTM, 3D CNN và Two-stream Network. Giai đoạn gần đây, từ 2020 đến 2025, các hướng YOLO kết hợp tracking, Transformer, kiến trúc multi-scale và attention mechanism được quan tâm nhiều hơn trong các tổng quan gần đây về violence detection [1, 2].

Một số bộ dữ liệu thường được sử dụng trong lĩnh vực này gồm Hockey Fight Dataset và Movies Dataset của Nievas và cộng sự [3], UCF-Crime, RWF-2000, XD-Violence và Real Life Violence Situations. Các bộ dữ liệu này cung cấp nền tảng quan trọng để so sánh mô hình. Tuy nhiên, mỗi bộ dữ liệu có bối cảnh riêng. Hockey Fight thiên về thể thao, Movies Dataset lấy từ phim, UCF-Crime và RWF-2000 gần với camera giám sát hơn nhưng chưa thật sự đặc thù cho môi trường trường học Việt Nam.

Bảng 2: Timeline phát triển các phương pháp phát hiện bạo lực trong video

Giai đoạn	Hướng phát triển chính
2011–2016	Đặc trưng thủ công: HOG, Optical Flow, BoW, SVM
2016–2020	CNN + RNN/LSTM, 3D CNN, Two-stream Network
2020–2025	YOLO + Tracking, Transformer, Multi-scale, Attention

Chương này không liệt kê rời rạc từng công trình, mà phân tích theo nhóm phương pháp. Cách trình bày này giúp làm rõ ưu điểm, hạn chế và khoảng trống nghiên cứu của từng hướng tiếp cận. Từ đó, đề tài xác định cơ sở để đề xuất pipeline phát hiện bạo lực

học đường dựa trên YOLO11s, ByteTrack và mô hình CNN–BiLSTM–Attention theo từng track người.

2.2 Nhóm 1: Tiếp cận CNN + RNN/LSTM trên toàn video

Nhóm phương pháp CNN + RNN/LSTM sử dụng CNN để trích xuất đặc trưng không gian từ từng frame, sau đó dùng RNN, LSTM hoặc Bi-LSTM để học quan hệ thời gian giữa các frame. Đây là một trong những hướng tiếp cận phổ biến trong giai đoạn học sâu bắt đầu được áp dụng mạnh vào nhận diện hành động từ video.

Sudhakaran và Lanz đề xuất mô hình kết hợp VGG-16 và ConvLSTM cho bài toán phát hiện video bạo lực [4]. Trong phương pháp này, VGG-16 trích xuất đặc trưng từ frame, còn ConvLSTM xử lý chuỗi đặc trưng theo thời gian. Kết quả trên Hockey Fight, Movies và Crowd Violence cho thấy hướng kết hợp đặc trưng không gian–thời gian có hiệu quả cao. Tuy nhiên, mô hình vẫn xử lý ở cấp video, chưa xác định được cá nhân nào gây ra hành vi bạo lực. Ngoài ra, VGG-16 là backbone nặng, khó phù hợp với yêu cầu triển khai nhẹ.

Một hướng liên quan là sử dụng CNN kết hợp Bi-LSTM cho nhận diện hành động. Các nghiên cứu của Ullah và cộng sự cho thấy Bi-LSTM có lợi thế trong việc khai thác ngữ cảnh hai chiều của chuỗi hành động. Thay vì chỉ nhìn từ quá khứ đến hiện tại, Bi-LSTM có thể học cả thông tin trước và sau một thời điểm trong chuỗi. Điều này phù hợp với hành vi bạo lực, vì nhiều tình huống chỉ rõ nghĩa khi quan sát đủ diễn tiến trước và sau va chạm. Tuy nhiên, các nghiên cứu này thường tập trung vào action recognition hoặc anomaly detection tổng quát, chưa chuyên biệt cho bạo lực học đường.

Akti và cộng sự tiếp tục phát triển hướng CNN + Bi-LSTM bằng cách bổ sung attention layer cho bài toán fight detection từ camera giám sát. Attention giúp mô hình tập trung hơn vào các timestep quan trọng thay vì xem mọi frame có vai trò như nhau; các nghiên cứu gần đây cũng khai thác attention để nhận diện và định vị vùng/thời điểm bạo lực trong video [5]. Đây là ý tưởng có giá trị cho đề tài, vì hành vi bạo lực thường chỉ xuất hiện trong một số khoảnh khắc ngắn của video. Dù vậy, hướng này vẫn chủ yếu phân loại ở cấp video và chưa khai thác tracking từng người.

Phân tích chung nhóm 1: ưu điểm lớn nhất của nhóm CNN + LSTM là khả năng kết hợp đặc trưng không gian và thời gian một cách tương đối rõ ràng. CNN học biểu diễn hình ảnh, còn LSTM hoặc Bi-LSTM học diễn tiến hành động. Tuy nhiên, các mô hình trong nhóm này thường xử lý toàn bộ video hoặc clip, nên khó xác định người cụ thể liên quan đến hành vi bạo lực. Khi bối cảnh đông người, cách phân loại video-level có thể bị nhiễu bởi nền, người đi ngang hoặc các hoạt động bình thường trong cùng khung hình.

Từ nhóm này, đề tài rút ra hai khoảng trống quan trọng. Thứ nhất, cần cơ chế phân tích theo từng track người thay vì chỉ phân loại toàn video. Thứ hai, nhiều mô hình chỉ sử dụng một cách mô hình hóa thời gian duy nhất, nên chưa bắt tốt chuyển động ở nhiều

tỉ lệ khác nhau. Đây là cơ sở để đề tài sử dụng *per-track classification* và Multi-scale Temporal Conv1D trong kiến trúc đề xuất.

2.3 Nhóm 2: Tiếp cận 3D CNN (C3D, I3D, SlowFast)

Khác với CNN 2D kết hợp LSTM, 3D CNN mở rộng phép tích chập sang cả chiều thời gian. Thay vì xử lý từng frame riêng lẻ, mô hình nhận vào một khối video gồm nhiều frame và dùng kernel 3D để học đồng thời đặc trưng không gian và chuyển động. Đây là cách tiếp cận tự nhiên đối với dữ liệu video.

C3D của Tran và cộng sự là một trong những mô hình tiêu biểu cho hướng này. Mô hình dùng các kernel 3D để trích xuất đặc trưng spatio-temporal theo cơ chế end-to-end. Ưu điểm là không cần thiết kế đặc trưng thủ công và không cần tách riêng bước trích xuất frame feature với bước temporal modeling. Tuy nhiên, C3D có số tham số lớn, chi phí tính toán cao và receptive field thời gian tương đối cố định.

I3D của Carreira và Zisserman tiếp cận theo hướng “inflate” các mạng CNN 2D thành mạng 3D, đồng thời kết hợp two-stream RGB và Optical Flow. Cách làm này tận dụng được trọng số pretrain từ ImageNet và đạt kết quả tốt trên các benchmark lớn. Tuy nhiên, việc tính Optical Flow làm tăng đáng kể chi phí suy luận, còn mô hình 3D vẫn cần GPU mạnh để huấn luyện và triển khai hiệu quả.

SlowFast Networks của Feichtenhofer và cộng sự thiết kế hai nhánh xử lý song song: nhánh Slow tập trung vào ngữ nghĩa không gian ở tốc độ frame thấp, còn nhánh Fast tập trung vào chuyển động ở tốc độ frame cao. Ý tưởng này rất mạnh cho action recognition tổng quát, nhưng kiến trúc tương đối phức tạp và nặng so với yêu cầu của một hệ thống cảnh báo có thể chạy trên phần cứng phổ thông.

Phân tích chung nhóm 2: 3D CNN có ưu điểm là xử lý đồng thời không gian và thời gian, pipeline gọn về mặt ý tưởng và có khả năng học đặc trưng chuyển động trực tiếp. Tuy nhiên, điểm yếu lớn là chi phí tính toán. Các mô hình như C3D, I3D và SlowFast thường có hàng chục triệu tham số và yêu cầu tài nguyên GPU đáng kể. Ngoài ra, nhiều mô hình vẫn phân loại ở cấp video hoặc clip, chưa giải quyết trực tiếp câu hỏi người nào trong khung hình đang thực hiện hành vi bạo lực.

Khoảng trống rút ra từ nhóm này là cần một kiến trúc nhẹ hơn nhưng vẫn học được đặc trưng thời gian. Thay vì dùng 3D CNN nặng trên toàn video, đề tài lựa chọn Spatial CNN gọn để trích xuất đặc trưng từng crop người, sau đó dùng Multi-scale Temporal Conv1D và Bi-LSTM để mô hình hóa chuyển động. Cách này giảm chi phí tính toán và phù hợp hơn với pipeline per-track.

2.4 Nhóm 3: Tiếp cận dựa trên YOLO Detection + Tracking

Các nghiên cứu gần đây bắt đầu quan tâm đến việc kết hợp phát hiện đối tượng và tracking trước khi phân loại hành vi. Đây là hướng phù hợp với bài toán giám sát thực tế,

vì hệ thống không chỉ cần biết video có bạo lực hay không, mà còn cần biết đối tượng nào liên quan đến sự kiện. Một số công trình mới cũng khai thác họ YOLO hoặc biến thể YOLO chuyên biệt cho bài toán phát hiện bạo lực nhằm cân bằng giữa tốc độ và độ chính xác [6, 7].

Singh và cộng sự đề xuất hướng phát hiện bạo lực học đường sử dụng YOLO-based Object Detection kết hợp Human Activity Recognition. Pipeline gồm phát hiện người, tracking, trích xuất đặc trưng và phân loại hành vi. Ưu điểm của công trình này là đặt bài toán trong bối cảnh trường học và sử dụng YOLO để tạo nền tảng phân tích theo đối tượng. Tuy nhiên, bộ phân loại phía sau còn tương đối đơn giản, chưa khai thác sâu temporal modeling bằng LSTM hoặc Attention.

Rend và cộng sự xây dựng pipeline real-time violence detection sử dụng YOLOv5, DeepSORT và CNN classifier. Hướng này có ưu điểm về khả năng chạy gần thời gian thực và tracking đa đối tượng. Tuy nhiên, nếu bộ phân loại chủ yếu dựa trên frame hoặc đặc trưng cục bộ, mô hình có thể chưa học đủ diễn tiến thời gian của hành vi. Với bạo lực, một frame đơn lẻ rất dễ gây nhầm giữa hành động mạnh bình thường và hành vi nguy hiểm.

Abdali và Al-Tuma kết hợp YOLOv4 với pose estimation để phát hiện bạo lực trong video thực tế. Skeleton giúp giảm phụ thuộc vào màu sắc, trang phục và nền, vì mô hình tập trung vào cấu trúc cơ thể. Tuy nhiên, pose estimation cần thêm chi phí tính toán và dễ giảm chất lượng khi người ở xa camera, bị che khuất hoặc bounding box quá nhỏ. Đây là những tình huống thường gặp trong camera giám sát trường học.

YOLO là nền tảng quan trọng cho hướng tiếp cận này nhờ khả năng phát hiện đối tượng nhanh trong thời gian thực [8]. Trong đề tài, YOLO11s từ Ultralytics được sử dụng để phát hiện lớp người trong từng frame [9]. Sau đó, ByteTrack được dùng để duy trì ID đối tượng qua thời gian [10]. Việc kết hợp detection và tracking tạo điều kiện để chuyển từ phân loại video-level sang phân tích theo từng track người.

Phân tích chung nhóm 3: ưu điểm của YOLO + Tracking là đưa bài toán về gần thực tế triển khai hơn. Hệ thống có thể phát hiện từng người, theo dõi chuyển động của từng đối tượng và tạo chuỗi dữ liệu đầu vào rõ ràng cho mô hình phân loại. Tuy nhiên, nhiều công trình trong nhóm này vẫn dùng bộ phân loại đơn giản như MLP, CNN đơn lẻ hoặc SVM, nên chưa tận dụng được khả năng mô hình hóa thời gian sâu bằng Bi-LSTM và Attention.

Khoảng trống chính của nhóm này là thiếu sự kết hợp đầy đủ giữa YOLO tracking và deep temporal modeling. Vì vậy, đề tài kế thừa phần detection/tracking, nhưng thay classifier đơn giản bằng kiến trúc Spatial CNN – Multi-scale Temporal Conv1D – Bi-LSTM – Temporal Attention. Ngoài ra, đề tài bổ sung cơ chế quyết định đa tầng ở cấp track và video để giảm cảnh báo nhầm.

2.5 Nhóm 4: Tiếp cận Two-stream và Optical Flow

Two-stream Network là hướng tiếp cận kết hợp hai nguồn thông tin: luồng RGB thể hiện nội dung hình ảnh và luồng chuyển động, thường là Optical Flow hoặc frame difference. Ý tưởng chính là hành vi bạo lực không chỉ thể hiện qua hình dáng đối tượng mà còn qua cường độ và hướng chuyển động giữa các frame.

Islam và cộng sự đề xuất một mạng two-stream hiệu quả cho violence detection. Mô hình sử dụng Separable ConvLSTM, đồng thời khai thác frame đã giảm nhiễu nền và frame difference để học chuyển động. Việc dùng separable convolution giúp giảm số tham số so với ConvLSTM thông thường. Tuy nhiên, hệ thống vẫn là video-level và phụ thuộc vào các bước tiền xử lý nền, làm tăng độ phức tạp khi triển khai thực tế.

Cheng và cộng sự đóng góp bộ dữ liệu RWF-2000, một benchmark quan trọng gồm các video giám sát thực tế cho bài toán violence detection. Công trình này cũng sử dụng hướng kết hợp thông tin chuyển động như optical flow hoặc flow-gated mechanism. Điểm mạnh là dữ liệu gần với giám sát thực tế hơn các bộ dữ liệu thể thao hoặc phim. Tuy nhiên, optical flow thường tốn chi phí tính toán cao và làm chậm quá trình suy luận.

Phân tích chung nhóm 4: Optical Flow cung cấp thông tin chuyển động trực tiếp và hữu ích, đặc biệt trong những tình huống hình ảnh tĩnh không đủ để phân biệt hành vi. Two-stream fusion thường giúp cải thiện độ chính xác so với chỉ dùng RGB. Tuy nhiên, chi phí tính Optical Flow là rào cản lớn đối với hệ thống cần chạy gần thời gian thực. Ngoài ra, việc lưu trữ hoặc truyền thêm luồng optical flow cũng làm tăng yêu cầu bộ nhớ và độ phức tạp pipeline.

Khoảng trống rút ra là cần một cách nắm bắt thông tin thời gian mà không phụ thuộc vào optical flow. Đề tài giải quyết theo hướng học temporal pattern trực tiếp trên đặc trưng CNN bằng Multi-scale Temporal Conv1D, sau đó dùng Bi-LSTM và Attention để mô hình hóa chuỗi. Cách này nhẹ hơn optical flow và phù hợp hơn với mục tiêu triển khai trên cấu hình phổ thông.

2.6 Nhóm 5: Tiếp cận Transformer và Attention

Transformer và attention mechanism đã tạo ra nhiều bước tiến trong nhận diện hành động từ video. Khác với LSTM xử lý chuỗi tuần tự, self-attention có thể học quan hệ giữa các vị trí trong chuỗi một cách linh hoạt hơn. Với video, attention có thể áp dụng theo không gian, thời gian hoặc kết hợp cả hai, như các hướng TimeSformer và Multiscale Vision Transformer trong video understanding [11, 12].

ViViT của Arnab và cộng sự là một hướng pure-transformer cho video classification [13]. Mô hình chia video thành các token và dùng attention để học quan hệ không gian–thời gian. Kết quả trên các benchmark lớn cho thấy tiềm năng của Transformer trong video understanding. Tuy nhiên, mô hình kiểu này thường cần pretrain trên tập dữ liệu rất lớn và tài nguyên tính toán mạnh, không phù hợp với bộ dữ liệu nhỏ trong phạm vi

đồ án.

Video Swin Transformer của Liu và cộng sự mở rộng Swin Transformer sang video bằng cơ chế 3D shifted windows [14]. Cách làm này giúp attention cục bộ hiệu quả hơn so với attention toàn cục và giảm chi phí so với một số Transformer thuần. Một số biến thể gần đây còn kết hợp keyframe với Video Swin để cải thiện violence detection [15]. Dù vậy, Video Swin vẫn là mô hình tương đối nặng, cần GPU mạnh và chưa phải lựa chọn tối ưu cho pipeline thử nghiệm cần gọn nhẹ.

Accattoli và cộng sự kết hợp 3D CNN với SVM cho violence detection. Đây là hướng lai giữa deep learning và machine learning truyền thống. Mô hình 3D CNN trích xuất đặc trưng spatio-temporal, sau đó SVM thực hiện phân loại. Cách tiếp cận này có thể đạt kết quả tốt trên một số bộ dữ liệu nhỏ, nhưng không end-to-end, vẫn xử lý video-level và chưa khai thác attention theo thời gian.

Phân tích chung nhóm 5: Transformer mạnh vì có khả năng học quan hệ dài hạn và chọn lọc thông tin quan trọng thông qua attention. Tuy nhiên, mô hình Transformer cho video thường cần nhiều dữ liệu và tài nguyên. Với bộ dữ liệu 389 video, việc sử dụng Transformer lớn có nguy cơ overfitting và khó huấn luyện ổn định. Vì vậy, đề tài không dùng Transformer đầy đủ, mà chỉ kế thừa ý tưởng attention ở mức nhẹ hơn thông qua Temporal Attention đặt sau Bi-LSTM [16].

Bảng 3: Tổng hợp 15 công trình nghiên cứu liên quan

#	Tác giả	Năm	Phương pháp	Best Acc	Hạn chế chính
1	Sudhakaran & Lanz	2017	VGG-16 + ConvLSTM	97.1% (HF)	Video-level, nặng
2	Ullah et al.	2018	CNN + DB-LSTM	91.2% (UCF)	Video-level
3	Ullah et al.	2021	CNN + BiLSTM anomaly	~87%	Binary anomaly only
4	Akti et al.	2019	Xception + BiLSTM + Attn	SOTA (HF)	Small dataset
5	Tran et al.	2015	C3D	90.4% (UCF)	Nặng, cần GPU
6	Carreira & Zisserman	2017	I3D	97.9% (UCF)	Cần Optical Flow
7	Feichtenhofer et al.	2019	SlowFast	79.0% (K400)	Compute cao
8	Singh et al.	2024	YOLOv8 + tracking + MLP	92.3%	Classifier đơn giản
9	Rend et al.	2023	YOLOv5 + DeepSORT + CNN	88.2%	Thiếu temporal model
10	Abdali & Al-Tuma	2022	YOLOv4 + pose + SVM	91.2% (RLVS)	Pose tốn tính toán
11	Islam et al.	2021	SepConvLSTM two-stream	87.25% (RWF)	Cần background suppression
12	Cheng et al.	2021	FlowGate + RWF-2000	87.25% (RWF)	Optical Flow chậm
13	Arnab et al.	2021	Video Transformer	SOTA (K400)	Cần pretrain lớn
14	Liu et al.	2022	Video Swin Transformer	84.9% (K400)	Nặng, cần GPU
15	Accattoli et al.	2020	3D CNN + SVM	High (HF)	Không end-to-end

Ghi chú: HF là Hockey Fight, RWF là RWF-2000, UCF là UCF-101 hoặc UCF-Crime tùy bối cảnh công trình, RLVS là Real Life Violence Situations và K400 là Kinetics-400.

2.7 Tổng hợp và phân tích khoảng trống nghiên cứu

Từ phân tích các nhóm công trình trên, đề tài xác định bảy khoảng trống nghiên cứu chính. Các khoảng trống này không chỉ xuất phát từ chỉ số accuracy, mà còn từ khả năng triển khai, khả năng giải thích kết quả và mức độ phù hợp với bối cảnh trường học.

Bảng 4: Phân tích khoảng trống nghiên cứu

Mã	Khoảng trống	Nhóm công trình bị ảnh hưởng
G1	Thiếu phân tích per-track; đa số phân loại video-level nên không xác định được cá nhân liên quan đến bạo lực.	CNN+LSTM, 3D CNN, Two-stream, Transformer
G2	Single-scale temporal analysis; chỉ dùng một loại kernel/window nên dễ bỏ sót chuyển động ở nhiều tỉ lệ thời gian.	CNN+LSTM, YOLO+Tracking, 3D CNN
G3	Mô hình quá nặng cho triển khai thực tế trên CPU hoặc edge device.	3D CNN, I3D, SlowFast, Transformer
G4	Thiếu kết hợp YOLO tracking với deep temporal modeling như Bi-LSTM và Attention.	Nhóm YOLO+Tracking
G5	Thiếu cơ chế quyết định đa tầng để giảm false positive khi tổng hợp kết quả.	Phần lớn công trình dùng single-level decision
G6	Phụ thuộc Optical Flow để lấy thông tin chuyển động, làm tăng chi phí tính toán và giảm tốc độ suy luận.	Two-stream, Flow-based methods
G7	Thiếu dataset phù hợp bối cảnh trường học Việt Nam; nhiều bộ dữ liệu đến từ thể thao, phim hoặc camera giám sát chung.	Hầu hết các benchmark phổ biến

Bảng 5: Tóm tắt các khoảng trống nghiên cứu chính

Nhóm vấn đề	Khoảng trống tương ứng
Đối tượng phân tích	G1: thiếu per-track classification
Thời gian	G2: thiếu multi-scale temporal analysis; G6: phụ thuộc Optical Flow
Triển khai	G3: mô hình nặng, khó chạy CPU/edge
Quyết định	G5: thiếu cơ chế track-level + video-level
Dữ liệu	G7: thiếu dữ liệu trường học phù hợp

Các khoảng trống trên cho thấy bài toán phát hiện bạo lực học đường không chỉ cần một mô hình có accuracy cao. Hệ thống còn cần xác định đúng đối tượng, chạy đủ nhanh, giảm cảnh báo nhầm và phù hợp với dữ liệu trường học. Đây là lý do đề tài không chọn một mô hình video lớn có sẵn, mà thiết kế pipeline theo hướng nhẹ, có tracking và có cơ chế tổng hợp kết quả nhiều tầng.

2.8 Định hướng nghiên cứu của đề tài

Từ bảy khoảng trống đã phân tích, đề tài chọn hướng giải quyết đồng thời các vấn đề quan trọng nhất bằng một pipeline kết hợp phát hiện người, tracking, phân tích chuỗi và tổng hợp kết quả. Cụ thể, định hướng nghiên cứu gồm các điểm sau:

- **Per-track classification:** sử dụng YOLO11s và ByteTrack để phát hiện và tracking từng người, sau đó phân tích hành vi trên từng track độc lập. Hướng này giải quyết G1 bằng cách chuyển trọng tâm từ toàn cảnh sang từng đối tượng.
- **Multi-scale Temporal Conv1D:** dùng ba kernel song song $k = 3, 5, 7$ để bắt chuyển động ở các tỉ lệ ngắn, trung bình và dài. Thành phần này giải quyết G2 và giảm nhu cầu dùng Optical Flow ở G6.
- **Kiến trúc nhẹ:** thiết kế Spatial CNN gọn thay vì dùng backbone lớn như VGG-16, ResNet hoặc Transformer. Hướng này giúp giải quyết G3 và phù hợp hơn với mục tiêu triển khai thực tế.
- **YOLO tracking + Bi-LSTM + Attention:** kết hợp detection/tracking với temporal modeling sâu hơn, gồm Multi-scale Conv1D, Bi-LSTM và Temporal Attention. Đây là cách giải quyết G4.
- **Cơ chế quyết định đa tầng:** áp dụng ngưỡng track-level 45% và tổng hợp video-level bằng biến `max_violent_persons`; video được đánh dấu bạo lực khi

$\text{max_violent_persons} \geq 1$, giải quyết G5.

- **Dataset trường học:** tự xây dựng bộ dữ liệu 389 video có annotation CVAT, trong đó có 189 video bạo lực và 200 video không bạo lực, nhằm giảm khoảng trống G7.


Hướng tiếp cận của đề tài kết hợp ưu điểm từ nhiều nhóm công trình. Từ nhóm YOLO + Tracking, đề tài kế thừa khả năng phát hiện và theo dõi từng người. Từ nhóm CNN + LSTM, đề tài kế thừa cách mô hình hóa chuỗi thời gian. Từ nhóm Two-stream, đề tài học được tầm quan trọng của chuyển động nhưng thay Optical Flow bằng Multi-scale Conv1D để giảm chi phí. Từ nhóm Transformer, đề tài kế thừa ý tưởng attention nhưng triển khai dưới dạng Temporal Attention nhẹ hơn. Nhờ đó, pipeline đề xuất vừa bám sát bối cảnh thực tế, vừa phù hợp với tài nguyên và dữ liệu của đề án.

CHƯƠNG 3. KIẾN TRÚC ĐỀ XUẤT

3.1 Pipeline tổng quan hệ thống

Hệ thống đề xuất được thiết kế theo dạng pipeline gồm năm bước liên tiếp. Mỗi bước xử lý một nhóm nhiệm vụ riêng, đồng thời giải quyết một hoặc nhiều khoảng trống nghiên cứu đã phân tích ở Chương 2. Cách tổ chức theo pipeline giúp hệ thống rõ ràng, dễ kiểm thử và có thể thay thế từng thành phần khi cần tối ưu.

Năm bước chính của pipeline gồm: thu thập dữ liệu từ camera, tiền xử lý và chuẩn hóa hình ảnh dữ liệu, phát hiện và trích xuất thông tin, phân loại hành động bạo lực/ bình thường, cuối cùng là phát hiện và cảnh báo theo thời gian gần thực. Đầu ra của bước trước là đầu vào của bước sau, tạo thành một quy trình khép kín từ video thô đến kết quả cảnh báo.



Hình 2: Sơ đồ tổng quan pipeline 5 bước của hệ thống phát hiện bạo lực học đường

Luồng xử lý bắt đầu từ video thô được thu thập từ camera an ninh hoặc được upload thông qua ứng dụng SafeWatch. Video sau đó được chuẩn hóa FPS, cắt vùng người theo bounding box, resize về kích thước thống nhất, normalize giá trị pixel và chia thành các cửa sổ trượt. Ở bước phát hiện và trích xuất đặc trưng, YOLO11s kết hợp ByteTrack tạo track cho từng người, Spatial CNN trích xuất đặc trưng không gian và Multi-scale Temporal Conv1D phân tích chuyển động ở nhiều tỉ lệ thời gian. Tiếp theo, Bi-LSTM và Temporal Attention phân loại hành vi ở từng window. Cuối cùng, cơ chế quyết định đa tầng tổng hợp kết quả ở cấp track và cấp video để đưa ra cảnh báo.

Triết lý thiết kế của pipeline là *modular* và hướng đến khả năng triển khai. Mỗi module có nhiệm vụ rõ ràng: YOLO11s phát hiện người, ByteTrack duy trì track ID, Spatial CNN học đặc trưng từng frame, Multi-scale Conv1D học chuyển động cục bộ, Bi-LSTM học ngữ cảnh chuỗi, Attention chọn thời điểm quan trọng và bộ quyết định đa tầng giảm cảnh báo nhầm. Thiết kế này cho phép thay thế từng module mà không phải viết lại toàn bộ hệ thống.

Ngoài ra, pipeline được tối ưu theo hướng tương đối nhẹ. Thay vì sử dụng 3D CNN hoặc Transformer lớn trên toàn bộ video, hệ thống chỉ phân tích crop của từng người và dùng mô hình khoảng **2.8 triệu tham số**. Điều này phù hợp với mục tiêu triển khai thử

nghiệm trên cấu hình phổ thông, đồng thời vẫn giữ được khả năng học đặc trưng không gian–thời gian cần thiết cho bài toán phát hiện bạo lực.

3.2 Bước 1: Thu thập dữ liệu từ camera

Bước đầu tiên của hệ thống là thu thập dữ liệu video. Trong quá trình huấn luyện, dữ liệu gồm **389 video**, được chia thành hai nhóm: **189 video bạo lực** và **200 video không bạo lực**. Các video này được tổng hợp từ năm bộ dữ liệu công khai gồm Real Life Violence Dataset, fight-detection-surv-dataset-master, SCVD, RWF-2000, A-Dataset-for-Automatic-Violence-Detection-in-Videos-master và một phần video do nhóm tự thu thập.

Trong giai đoạn triển khai thực tế, nguồn dữ liệu có thể đến từ video được upload qua ứng dụng web hoặc từ luồng camera an ninh. Với phạm vi đồ án, hệ thống tập trung vào xử lý video upload qua SafeWatch App. Hướng kết nối trực tiếp với RTSP stream từ camera được xem là hướng phát triển tiếp theo khi hệ thống cần vận hành liên tục theo thời gian thực.

Việc xây dựng bộ dữ liệu riêng từ nhiều nguồn là cần thiết vì từng bộ dữ liệu công khai riêng lẻ chưa phản ánh đầy đủ bối cảnh trường học Việt Nam. Video trường học có nhiều đặc thù như học sinh mặc đồng phục, mật độ người cao vào giờ ra chơi, hành vi đùa giỡn dễ bị nhầm với bạo lực và điều kiện ánh sáng khác nhau giữa sân trường, hành lang và lớp học. Đây chính là khoảng trống G7 đã nêu ở Chương 2.



Hình 3: Ví dụ frame mẫu về tình huống bạo lực trong bối cảnh trường học

Dữ liệu thu thập được tổ chức theo nhãn video ban đầu. Tuy nhiên, pipeline không sử

dụng trực tiếp toàn bộ khung hình để phân loại. Thay vào đó, hệ thống phát hiện người, tạo track và phân tích từng track độc lập. Cách tổ chức này giúp bộ dữ liệu phù hợp hơn với hướng *per-track classification* của đề tài.

3.3 Bước 2: Tiền xử lý và chuẩn hóa dữ liệu

Video đầu vào từ nhiều nguồn thường khác nhau về FPS, độ phân giải, tỷ lệ khung hình, định dạng file và chất lượng hình ảnh. Nếu đưa trực tiếp vào mô hình, sự khác biệt này làm input thiếu nhất quán và khiến quá trình huấn luyện kém ổn định. Vì vậy, tiền xử lý là bước bắt buộc để chuẩn hóa dữ liệu trước khi huấn luyện và suy luận.

Quy trình tiền xử lý gồm bốn nhóm thao tác chính: chuẩn hóa FPS, crop và resize vùng người, normalize pixel, sau đó tạo Sliding Window. Các bước này được tóm tắt trong Bảng 6.

Bảng 6: Các bước chuẩn hóa dữ liệu trong pipeline tiền xử lý

#	Bước	Chi tiết kỹ thuật
1	Chuẩn hóa FPS	Resample video về 30 FPS. Video FPS cao được lấy cách frame, video FPS thấp được lặp/nội suy frame để giữ nhịp thời gian gần nhất.
2	Crop + Resize	Crop bounding box người, mở rộng vùng crop khoảng 5%, sau đó resize về 96×96 px bằng bilinear interpolation.
3	Normalize pixel	Chuyển BGR sang RGB, đổi sang <code>float32</code> , chia 255 để đưa về khoảng $[0,1]$, sau đó transpose từ HWC sang CHW.
4	Sliding Window	Chia track thành window 30 frame, step 4 frame; dữ liệu đã xử lý được lưu cache dạng <code>.npy</code> để tăng tốc các lần huấn luyện sau.

Sliding Window được chọn vì mỗi track người có độ dài khác nhau. Nếu dùng padding hoặc truncating, track dài có thể bị mất thông tin còn track ngắn bị thêm nhiều frame đệm không có ý nghĩa. Nếu dùng global average pooling, thông tin thứ tự thời gian gần như bị mất. Trong khi đó, Sliding Window giữ được cấu trúc thời gian cục bộ, tạo input cố định cho mô hình và đồng thời tăng số lượng mẫu huấn luyện.

Với window dài 30 frame ở 30 FPS, mỗi mẫu tương ứng khoảng một giây video. Bước trượt 4 frame tạo độ chồng lấp lớn giữa các window, giúp giảm nguy cơ bỏ sót các hành vi ngắn. Ví dụ, một track dài 150 frame có thể tạo số window theo công thức:

$$N_{win} = \left\lfloor \frac{150 - 30}{4} \right\rfloor + 1 = 31 \quad (1)$$

Điều này cho thấy một track dài có thể sinh ra nhiều mẫu huấn luyện khác nhau, giúp mô hình quan sát nhiều vị trí thời gian của cùng một hành vi. Đây cũng là một dạng tăng cường dữ liệu tự nhiên, đặc biệt hữu ích khi số lượng video gốc chưa lớn.

3.4 Bước 3: Phát hiện đối tượng và trích xuất đặc trưng

Bước 3 gồm ba thành phần chính: YOLO11s + ByteTrack để phát hiện và tracking người, Spatial CNN để trích xuất đặc trưng không gian, và Multi-scale Temporal Conv1D để phân tích chuyển động cục bộ ở nhiều tỉ lệ thời gian. Bước này giải quyết trực tiếp các khoảng trống G1, G2, G4 và G6 đã nêu ở Chương 2.

3.4.1 YOLO11s + ByteTrack – Phát hiện và tracking người

YOLO11s được sử dụng để phát hiện người trong từng frame. Hệ thống chỉ giữ lớp *person* vì người là đối tượng duy nhất cần phân tích hành vi. So với các mô hình YOLO cũ hơn, YOLO11s có kích thước gọn, tốc độ suy luận nhanh và dễ tích hợp với pipeline tracking của Ultralytics. Đây là lựa chọn phù hợp cho hệ thống cần cân bằng giữa độ chính xác và tốc độ, tương tự xu hướng dùng detector thời gian thực trong các nghiên cứu violence detection gần đây [6].

ByteTrack được dùng để liên kết các detection qua thời gian và tạo track ID cho từng người. Lý do chọn ByteTrack là thuật toán có khả năng tận dụng cả các detection có confidence thấp trong bước liên kết, từ đó giảm mất track khi người bị che khuất một phần hoặc chuyển động nhanh. So với DeepSORT, ByteTrack không cần trích xuất ReID feature nên nhẹ hơn và phù hợp hơn với pipeline thời gian gần thực.

Bảng 7: Tham số cấu hình YOLO11s tracking

Tham số	Giá trị / Ý nghĩa
Model	YOLO11s (yolo11s.pt)
Tracker	ByteTrack (bytetrack.yaml)
Confidence threshold	0.38
IoU threshold	0.55
Classes	[0] – chỉ phát hiện người
Persist	True, duy trì track ID qua frame
Image size	320×320, tối ưu tốc độ inference
Output	XML annotation chuẩn CVAT

Kết quả detection và tracking được dùng để cắt vùng ảnh của từng người, tạo thành chuỗi crop theo thời gian. Đây là bước chuyển quan trọng từ video-level sang per-track. Thay vì mô hình phải xử lý toàn cảnh có nhiều đối tượng, mỗi mẫu đầu vào chỉ tập trung vào một người cụ thể.

3.4.2 Spatial CNN – Trích xuất đặc trưng không gian

Spatial CNN nhận từng frame crop kích thước 96×96 và trích xuất vector đặc trưng không gian. Đề tài tự thiết kế CNN 4 block thay vì dùng backbone lớn như VGG-16 hoặc ResNet-50. Lý do là các backbone này có số tham số lớn, được pretrain cho phân loại ảnh tổng quát và chứa nhiều đặc trưng không cần thiết cho bài toán phát hiện bạo lực học đường.

Kiến trúc CNN tự thiết kế gồm các block tăng dần số kênh từ 32, 64, 128 đến 256. Các block đầu học cạnh, đường viền và chi tiết cơ thể; các block sâu hơn học tư thế, hình dạng và quan hệ không gian của đối tượng. Sau khối cuối, Adaptive Average Pooling đưa feature map về kích thước 2×2 , sau đó flatten và giảm chiều từ 1024 xuống 256.

Ưu điểm của Spatial CNN tự thiết kế là nhẹ và chuyên biệt hơn. Phần CNN chỉ chiếm khoảng 1.5 triệu tham số, nhỏ hơn nhiều so với VGG-16 hoặc ResNet-50. Điều này giúp giảm chi phí huấn luyện và suy luận, đồng thời phù hợp với mục tiêu triển khai trên phần cứng phổ thông.

3.4.3 Multi-scale Temporal Conv1D – Phân tích chuyển động

Sau khi Spatial CNN trích xuất đặc trưng cho từng frame, chuỗi đặc trưng có dạng $(B, 30, 256)$. Multi-scale Temporal Conv1D được dùng để học chuyển động trên chuỗi này. Khác với Optical Flow, Conv1D không cần tính toán thêm luồng chuyển động từ

ảnh gốc. Sự thay đổi giữa các vector đặc trưng liên tiếp đã phản ánh một phần thay đổi tư thế và vị trí của người.

Đề tài sử dụng ba kernel song song $k = 3, 5, 7$. Kernel nhỏ $k = 3$ phù hợp với chuyển động rất nhanh như cú đấm; kernel $k = 5$ phù hợp với xô đẩy hoặc va chạm trung bình; kernel $k = 7$ quan sát được hành vi kéo dài hơn như đuổi đánh hoặc vật lộn. Ba nhánh được concat lại thành 256 kênh, sau đó MaxPool1D giảm số timestep từ 30 xuống 15.

Cách thiết kế multi-scale này giải quyết khoảng trống G2, vì nhiều công trình trước chỉ dùng một thang thời gian. Đồng thời, nó cũng giảm phụ thuộc vào Optical Flow, qua đó giải quyết một phần G6 về chi phí tính toán.

3.5 Bước 4: Phân loại hành vi bạo lực / bình thường

Bước 4 nhận chuỗi đặc trưng sau Multi-scale Conv1D và thực hiện phân loại hành vi. Thành phần chính gồm Bi-LSTM, Temporal Attention và FC Classifier. Đây là phần giải quyết khoảng trống G4: kết hợp YOLO tracking với deep temporal modeling thay vì chỉ dùng classifier đơn giản.

3.5.1 Bi-LSTM – Phân tích chuỗi thời gian hai chiều

Bi-LSTM được sử dụng vì hành vi bạo lực cần được hiểu trong cả ngữ cảnh trước và sau một thời điểm. LSTM đơn hướng chỉ đọc chuỗi theo chiều thời gian từ quá khứ đến hiện tại. Trong khi đó, Bi-LSTM đọc theo cả hai chiều, giúp mô hình biết được diễn tiến trước hành động và hậu quả sau hành động. Ví dụ, hành động giơ tay có thể là vẫy chào hoặc chuẩn bị đánh; thông tin sau đó giúp phân biệt hai trường hợp này.

Mô hình sử dụng Bi-LSTM 2 lớp với input 256, hidden size 128 cho mỗi chiều. Do là bidirectional, output ở mỗi timestep có 256 chiều. Dropout 0.3 giữa hai lớp giúp giảm overfitting, đặc biệt khi bộ dữ liệu chưa lớn.

3.5.2 Temporal Attention – Tập trung khoảnh khắc quyết định

Không phải mọi timestep đều quan trọng như nhau. Một số frame chỉ là chuyển tiếp hoặc trạng thái đứng yên, trong khi một số frame chứa hành động chính như vung tay, va chạm hoặc ngã. Temporal Attention giúp mô hình gán trọng số cao hơn cho các timestep quan trọng và giảm ảnh hưởng của những timestep ít thông tin.

Cơ chế attention được thiết kế nhẹ hơn Transformer. Thay vì self-attention toàn cục có độ phức tạp cao, Temporal Attention trong đề tài sử dụng hai lớp tuyến tính: $256 \rightarrow 64 \rightarrow 1$, kết hợp hàm Tanh và Softmax để tạo trọng số thời gian. Vector ngữ cảnh cuối cùng là tổng có trọng số của các hidden state Bi-LSTM:

$$e_t = \tanh(W_1 h_t + b_1) \quad (2)$$

$$\alpha_t = \frac{\exp(W_2 e_t + b_2)}{\sum_j \exp(W_2 e_j + b_2)} \quad (3)$$

$$c = \sum_t \alpha_t h_t \quad (4)$$

Trong đó, h_t là hidden state tại timestep t , α_t là trọng số chú ý và c là vector ngữ cảnh 256 chiều dùng cho phân loại cuối cùng.

3.5.3 FC Classifier và ngưỡng phân loại

Sau Temporal Attention, vector ngữ cảnh được đưa qua FC Classifier có cấu trúc $256 \rightarrow 128 \rightarrow 64 \rightarrow 2$. Các lớp fully connected kết hợp Batch Normalization, ReLU và Dropout để tăng khả năng tổng quát hóa. Đầu ra của mô hình là logits hai lớp: *non-violence* và *violence*.

Trong quá trình huấn luyện, mô hình sử dụng Focal Loss để tập trung hơn vào các mẫu khó. Trong quá trình suy luận, logits được đưa qua Softmax để lấy xác suất $P(violence)$. Một window được xem là bạo lực nếu $P(violence) \geq 0.45$.

Ngưỡng 0.45 được chọn thay vì 0.50 vì bài toán an ninh ưu tiên Recall, tức hạn chế bỏ sót tình huống bạo lực. False Positive có thể được giảm tiếp bằng cơ chế quyết định đa tầng ở Bước 5, còn False Negative trong bối cảnh trường học có thể gây hậu quả nghiêm trọng hơn.

3.6 Bước 5: Phát hiện và cảnh báo thời gian thực

Bước cuối cùng của pipeline là tổng hợp kết quả dự đoán và phát cảnh báo. Đây là bước giải quyết khoảng trống G5: thay vì dùng một ngưỡng duy nhất ở cấp window hoặc video, đề tài sử dụng cơ chế quyết định đa tầng gồm track-level và video-level.

3.6.1 Logic kết luận đa tầng

Ở tầng thứ nhất, hệ thống tính trung bình xác suất $P(violence)$ của tất cả window thuộc cùng một track. Nếu xác suất trung bình lớn hơn hoặc bằng 45%, track đó được đánh dấu là track bạo lực. Cách làm này giúp tránh việc một window nhiều đơn lẻ làm sai kết luận của cả track.

$$P_{track} = \frac{1}{N} \sum_{i=1}^N P_i(violence) \quad (5)$$

$$label_{track} = \begin{cases} violence, & P_{track} \geq 0.45 \\ non-violence, & P_{track} < 0.45 \end{cases} \quad (6)$$


Ở tầng thứ hai, hệ thống tổng hợp số người/track bạo lực trong video thông qua biến `max_violent_persons`. Biến này biểu diễn số track hợp lệ được đánh dấu bạo lực lớn nhất trong quá trình phân tích video. Nếu `max_violent_persons` lớn hơn hoặc bằng 1, video được kết luận là có bạo lực. Các track quá ngắn, không đủ frame để tạo window đầy đủ, sẽ không được đưa vào bước tổng hợp.

$$max_violent_persons = \max_{t \in T} N_{violent_tracks}(t) \quad (7)$$

$$label_{video} = \begin{cases} violence, & max_violent_persons \geq 1 \\ non-violence, & max_violent_persons < 1 \end{cases} \quad (8)$$

Hai tầng quyết định giúp hệ thống ổn định hơn so với cách phân loại đơn tầng. Nếu một học sinh chạy nhanh qua camera và tạo xác suất cao ở một vài window, track-level averaging có thể làm giảm tác động của nhiễu.

Ở cấp video, tiêu chí có ít nhất một track bạo lực phù hợp với bài toán an ninh vì hệ thống cần cảnh báo ngay khi phát hiện dấu hiệu bạo lực. Trong triển khai, tiêu chí này được biểu diễn bằng điều kiện `max_violent_persons ≥ 1`.




Hình 4: Sơ đồ logic xử lý và cảnh báo của hệ thống SafeWatch


3.6.2 Hệ thống cảnh báo và ứng dụng SafeWatch

Sau khi video được kết luận là có bạo lực, hệ thống có thể kích hoạt các chức năng cảnh báo trong SafeWatch App. Backend FastAPI tiếp nhận video, gọi pipeline suy luận PyTorch và trả về kết quả có cấu trúc. Frontend Flutter Web hiển thị trạng thái xử lý, kết quả video-level, timeline nghi vấn và các thông tin cảnh báo cần thiết.

Các kênh cảnh báo được thử nghiệm gồm Gmail và Telegram. Email phù hợp với việc lưu trữ và báo cáo, trong khi Telegram phù hợp với cảnh báo nhanh trên thiết bị di động. Ngoài ra, giao diện có thể hiển thị dashboard, hàng chờ xử lý, lịch sử phân tích và các cấu hình kết nối server.



Hình 5: Giao diện menu điều hướng và dashboard tổng quan của SafeWatch App



Hình 6: Cảnh báo gửi tới Gmail và Telegram khi hệ thống phát hiện video có dấu hiệu bạo lực

Các chức năng cảnh báo chỉ đóng vai trò hỗ trợ ra quyết định. Trong môi trường trường học, kết quả từ AI cần được người quản lý kiểm tra lại trước khi đưa ra kết luận chính thức, đặc biệt với các tình huống nhạy cảm hoặc dễ gây hiểu lầm.

3.7 Tổng kết kiến trúc và mối liên hệ với khoảng trống

Bảng 8 đối chiếu từng bước của pipeline với các khoảng trống nghiên cứu đã xác định ở Chương 2. Qua đó có thể thấy kiến trúc đề xuất không chỉ là sự ghép nối các module kỹ thuật, mà được thiết kế có chủ đích để giải quyết các hạn chế của những hướng tiếp cận trước.


Bảng 8: Đối chiếu mỗi bước pipeline với khoảng trống nghiên cứu

Bước pipeline	Khoảng trống	Cách giải quyết
Thu thập dữ liệu	G7	Tổng hợp 389 video từ 5 dataset công khai và dữ liệu tự thu thập.
Tiền xử lý + Sliding Window	Hỗ trợ	Chuẩn hóa input, tăng số mẫu và giữ temporal dynamics.
YOLO11s + ByteTrack	G1, G4	Phân tích per-track thay vì video-level.
Spatial CNN	G3	CNN tự thiết kế gọn, tránh backbone quá nặng.
Multi-scale Conv1D	G2, G6	Kernel 3, 5, 7, thay thế Optical Flow tốn chi phí.
Bi-LSTM 2 lớp	G4	Mô hình hóa chuỗi hai chiều sau tracking.
Temporal Attention	G4	Tập trung vào timestep quan trọng, nhẹ hơn Transformer.
Multi-level Decision	G5	Hai tầng track-level 45% và video-level theo $\text{max_violent_persons} \geq 1$.

Bảng 9: Kiến trúc chi tiết mô hình ImprovedViolenceModel

Module	Cấu trúc	Output shape
Spatial CNN	4 block Conv2D + BN + ReLU + Pooling	$(B \times 30, 256, 2, 2)$
SpatialDropout2D	$p = 0.15$	$(B \times 30, 256, 2, 2)$
FC Reduce	$1024 \rightarrow 256$, BN, ReLU, Dropout(0.4)	$(B, 30, 256)$
Multi-scale Conv1D $k = 3$	$256 \rightarrow 128$, BN, ReLU	$(B, 128, 30)$
Multi-scale Conv1D $k = 5$	$256 \rightarrow 64$, BN, ReLU	$(B, 64, 30)$
Multi-scale Conv1D $k = 7$	$256 \rightarrow 64$, BN, ReLU	$(B, 64, 30)$
Concat + MaxPool1D	$128 + 64 + 64 = 256$ channels	$(B, 256, 15)$
Bi-LSTM	2 layers, hidden 128×2 , Dropout(0.3)	$(B, 15, 256)$
Temporal Attention	$256 \rightarrow 64 \rightarrow 1$, Tanh, Softmax	$(B, 256)$
FC Classifier	$256 \rightarrow 128 \rightarrow 64 \rightarrow 2$	$(B, 2)$

Tổng thể, mô hình có khoảng **2.8 triệu tham số**, kích thước file khoảng **8 MB**. Kiến trúc này nhẹ hơn đáng kể so với các backbone lớn hoặc mô hình video Transformer, nhưng vẫn giữ được các thành phần quan trọng cho bài toán: đặc trưng không gian, chuyển động đa tỉ lệ, ngữ cảnh thời gian hai chiều và attention theo timestep.



Hình 7: Kiến trúc tổng thể mô hình ImprovedViolenceModel trong pipeline huấn luyện

Hình 7 mô tả luồng xử lý bên trong mô hình ImprovedViolenceModel từ chuỗi ảnh crop của từng người đến nhãn phân loại cuối cùng. Đầu vào của mô hình là một window gồm 30 frame đã được chuẩn hóa về kích thước 96×96 . Mỗi frame trước hết đi qua Spatial CNN để trích xuất đặc trưng không gian, nhờ đó mô hình học được các thông tin như tư thế cơ thể, vùng tay chân, dáng đứng và hình dạng tổng quát của người trong từng thời điểm.

Sau khi có chuỗi đặc trưng theo thời gian, Multi-scale Temporal Conv1D tiếp tục phân tích chuyển động ở ba kích thước kernel khác nhau. Cách thiết kế này giúp mô hình

quan sát đồng thời các chuyển động rất ngắn như vung tay, các va chạm trung bình như xô đẩy và các hành vi kéo dài hơn như rượt đuổi hoặc vật lộn. Tiếp đó, Bi-LSTM bổ sung ngữ cảnh hai chiều để hiểu diễn tiến trước và sau hành động, còn Temporal Attention chọn ra những timestep quan trọng nhất trước khi đưa vào bộ phân loại cuối.

Điểm mạnh của kiến trúc trong Hình 7 là sự kết hợp cân bằng giữa độ nhẹ và khả năng mô hình hóa không gian–thời gian. Thay vì xử lý toàn bộ video bằng 3D CNN hoặc Transformer lớn, mô hình chỉ xử lý crop theo từng track người, sau đó dùng Conv1D, Bi-LSTM và Attention để học chuyển động. Nhờ vậy, kiến trúc phù hợp hơn với phạm vi dữ liệu 389 video và mục tiêu triển khai thử nghiệm trên cấu hình phổ thông, nhưng vẫn giữ được các thành phần cần thiết để phân biệt hành vi bạo lực với các chuyển động mạnh thông thường.

CHƯƠNG 4. THỰC NGHIỆM

4.1 Bộ dữ liệu (Dataset)

4.1.1 Nguồn gốc và cách thu thập

Bộ dữ liệu của đề tài được xây dựng bằng cách tổng hợp video từ các bộ dữ liệu công khai và một phần video do bản thân tự thu thập. Năm nguồn công khai được sử dụng gồm **Real Life Violence Dataset**, **fight-detection-surv-dataset-master**, **SCVD**, **RWF-2000** và **A-Dataset-for-Automatic-Violence-Detection-in-Videos-master**. Các video từ những nguồn này được chọn lọc lại, loại bỏ các đoạn không phù hợp và chuẩn hóa để phục vụ mục tiêu phát hiện hành vi bạo lực trong bối cảnh giám sát học đường.

Bên cạnh dữ liệu công khai, đề tài bổ sung thêm một số video tự thu thập nhằm tăng độ gần với bối cảnh sử dụng thực tế. Nhóm video này tập trung vào các tình huống có thể xuất hiện trong môi trường trường học như sân trường, hành lang, lớp học hoặc khu vực cổng trường. Việc kết hợp dữ liệu công khai với dữ liệu tự thu thập giúp bộ dữ liệu vừa có độ đa dạng nhất định, vừa phù hợp hơn với phạm vi bài toán của đề tài.

Bối cảnh video tương đối đa dạng, gồm sân trường, hành lang, lớp học và khu vực cổng trường. Điều kiện ghi hình cũng không hoàn toàn đồng nhất, có video ban ngày, video thiếu sáng, góc camera cao, góc camera ngang và các tình huống có nhiều người xuất hiện trong cùng khung hình. Sự đa dạng này giúp dữ liệu gần hơn với điều kiện triển khai thực tế, dù quy mô vẫn còn giới hạn trong phạm vi đồ án tốt nghiệp.

Quá trình xây dựng dữ liệu được thực hiện theo các bước: tải và tổng hợp video từ năm bộ dữ liệu công khai, bổ sung video tự thu thập, cắt thành các đoạn ngắn từ khoảng 3 đến 10 giây, loại bỏ các đoạn trùng lặp hoặc không rõ nội dung, sau đó đặt tên theo quy ước thống nhất. Các video thuộc lớp bạo lực được đặt tên theo dạng `v_001.mp4` đến `v_189.mp4`, còn các video không bạo lực được đặt tên theo dạng `nv_001.mp4` đến `nv_200.mp4`. Cách đặt tên này giúp quá trình quản lý dữ liệu, gán nhãn và chia tập được kiểm soát rõ ràng hơn.

4.1.2 Cấu trúc và thống kê

Sau quá trình thu thập, chọn lọc và kiểm tra lại, bộ dữ liệu ban đầu gồm **389 video**. Trong đó có **189 video bạo lực** và **200 video không bạo lực**. Tỷ lệ hai lớp tương đối cân bằng, giúp hạn chế tình trạng mô hình bị thiên lệch quá mạnh về lớp chiếm đa số.


Bảng 10: Thông tin thống kê bộ dữ liệu tự xây dựng

Thuộc tính	Chi tiết
Tổng số video	389
Violence (bạo lực)	189 video (v_001–v_189)
Non-violence (bình thường)	200 video (nv_001–nv_200)
Định dạng	.mp4, .avi
FPS gốc	24–60 fps
Độ phân giải gốc	Đa dạng
Thời lượng mỗi video	3–10 giây
Tổng dung lượng	Khoảng 1 GB
Annotation format	XML chuẩn CVAT

Dữ liệu không được đưa trực tiếp toàn bộ khung hình vào mô hình. Thay vào đó, hệ thống phát hiện và theo dõi từng người, sau đó trích xuất các track hợp lệ để tạo chuỗi đầu vào. Cách xử lý theo track giúp mô hình tập trung hơn vào hành vi của từng cá nhân và giảm nhiễu từ nền hoặc từ các đối tượng không liên quan.

Bảng 11: Thống kê tổng hợp bộ dữ liệu sau tiền xử lý

Chỉ tiêu	Giá trị
Tổng tracks được trích xuất	Khoảng 1.356 tracks
Tracks non-violence	863
Tracks violence	493
Tổng Sliding Windows	Khoảng 31656 windows
Phân chia Train (70%)	21681 windows
Phân chia Validation (20%)	6.750 windows
Phân chia Test (10%)	3225 windows
Phương pháp chia	Stratified Video Split theo video, không theo track



Đồ thị 1. Biểu đồ phân phối dữ liệu train/validation/test

4.1.3 Quy trình gán nhãn (Annotation)

Quá trình gán nhãn được thực hiện kết hợp giữa tự động và thủ công. Đầu tiên, YOLO11s kết hợp ByteTrack được sử dụng để phát hiện và theo dõi người trong video, sau đó xuất kết quả ra file XML theo chuẩn CVAT. Các file này tiếp tục được kiểm tra thủ công bằng CVAT để sửa bounding box bị lệch, xóa track không liên quan và bổ sung các track bị bỏ sót. Những nhãn đã hiệu chỉnh được lưu trong thư mục `fix_labels/` và được kiểm tra chất lượng bằng script `check_labels.py`.

Một vấn đề quan trọng của bộ dữ liệu là nhãn ban đầu chủ yếu ở cấp video. Khi một video được gán nhãn bạo lực, không phải mọi frame hoặc mọi cửa sổ trong video đó đều thật sự chứa hành vi bạo lực. Vì vậy, khi áp dụng Sliding Window, một số cửa sổ có thể mang nhãn bạo lực dù chỉ chứa đoạn chuyển tiếp hoặc đoạn chưa xảy ra va chạm. Đây là dạng nhãn yếu (weak label) ở cấp window.

Để giảm ảnh hưởng của nhãn yếu, đề tài sử dụng Label Smoothing nhằm tránh việc mô hình quá tự tin vào nhãn, Focal Loss để tập trung hơn vào các mẫu khó và cơ chế tổng hợp ở cấp video để không phụ thuộc vào một cửa sổ đơn lẻ. Dù vậy, hạn chế này vẫn cần được thừa nhận và là một hướng cải thiện quan trọng trong các phiên bản sau.

4.2 Phương pháp đánh giá

Mô hình được đánh giá bằng nhiều chỉ số thay vì chỉ sử dụng Accuracy. Với bài toán phát hiện bạo lực, việc dự đoán đúng tổng thể là cần thiết nhưng chưa đủ, vì bỏ sót một tình huống bạo lực có thể nghiêm trọng hơn một cảnh báo nhầm.

- **Accuracy:** phản ánh tỷ lệ dự đoán đúng tổng thể, được tính theo công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **Precision:** cho biết trong số các mẫu được dự đoán là bạo lực, có bao nhiêu mẫu thật sự là bạo lực:

$$Precision = \frac{TP}{TP + FP}$$

- **Recall:** cho biết trong số các mẫu bạo lực thật, có bao nhiêu mẫu được hệ thống phát hiện:

$$Recall = \frac{TP}{TP + FN}$$

- **F1-Score:** là trung bình điều hòa giữa Precision và Recall:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

- **Confusion Matrix:** cho phép phân tích chi tiết bốn nhóm kết quả gồm True Positive, True Negative, False Positive và False Negative.
- **Phân phối xác suất:** biểu đồ phân phối xác suất $P(violence)$ giúp quan sát khả năng phân tách giữa hai lớp.

Đề tài đánh giá mô hình trên hai tập dữ liệu. Tập validation chiếm khoảng 20% dữ liệu và được dùng trong quá trình huấn luyện để theo dõi mô hình, chọn checkpoint tốt nhất và kích hoạt Early Stopping. Tập test chiếm khoảng 10% dữ liệu, được tách độc lập và không dùng để lựa chọn siêu tham số, nhằm đánh giá khách quan hơn khả năng tổng quát hóa.

4.3 Cấu hình thực nghiệm (Setting)

4.3.1 Phần cứng và nền tảng

Các thí nghiệm huấn luyện được thực hiện trên môi trường Kaggle Notebooks. Đây là lựa chọn phù hợp với phạm vi đồ án vì cung cấp GPU miễn phí, đủ để huấn luyện và kiểm thử mô hình với bộ dữ liệu tự xây dựng.

Bảng 12: Cấu hình phần cứng và nền tảng thực nghiệm

Thành phần	Chi tiết
Nền tảng	Kaggle Notebooks
GPU	NVIDIA Tesla T100 (16GB VRAM)
GPU quota	30 giờ/tuần
RAM	Khoảng 13 GB
Disk	Khoảng 20 GB
Hệ điều hành	Linux (Kaggle Docker container)
Framework	PyTorch 2.x + CUDA
YOLO	Ultralytics YOLO 8.x
Python	3.11+
Inference triển khai	CPU thông thường (Windows/Linux)

4.3.2 Siêu tham số (Hyperparameters)

Bảng 13: Tổng hợp siêu tham số huấn luyện

Hyperparameter	Giá trị
Image size	96×96 px
Sequence length (window)	30 frame (khoảng 1 giây)
Window step	4 frame
Batch size	12
Max epochs	100
Learning rate	2e-4
Weight decay	3e-4
Early stopping patience	25 epochs
Violence threshold (track)	0.45 (45%)
Video decision threshold	$\text{max_violent_persons} \geq 1$
MixUp alpha	0.2
Focal Loss gamma	2.0
Label smoothing	0.1
Gradient clip norm	1.0
LR scheduler	5-epoch Warmup + Cosine Annealing Warm Restarts
Seed	42

Bảng 14: Các kỹ thuật Data Augmentation áp dụng

Kỹ thuật	Xác suất	Mô tả
Horizontal Flip	50%	Lật ngang toàn bộ sequence
Temporal Reverse	50%	Phát ngược sequence
Random Speed	30%	Tăng/giảm tốc 0.8x–1.2x
Brightness Jitter	50%	Thay đổi độ sáng $\pm 15\%$
Temporal Jitter	30%	Drop 1–2 frame hoặc lặp frame kề
Gaussian Noise	50%	Nhiều Gaussian với $\sigma = 0.015$
Random Erasing	25%	Xóa một vùng nhỏ trong ảnh

4.4 Kết quả thực nghiệm

4.4.1 Kết quả xây dựng bộ dữ liệu


Từ 389 video gốc, pipeline tiền xử lý đã trích xuất khoảng **1.356 tracks hợp lệ**, tức các track có đủ số frame tối thiểu để tạo chuỗi đầu vào cho mô hình. Sau khi áp dụng Sliding Window với độ dài **30 frame** và bước trượt **4 frame**, dữ liệu được mở rộng thành khoảng **21.000 windows**. Việc tăng số lượng mẫu theo cửa sổ giúp mô hình quan sát được nhiều biến thể chuyển động hơn mà không cần thu thập thêm quá nhiều video mới.

Dữ liệu được chia theo phương pháp Stratified Video Split với tỷ lệ 70% train, 20% validation và 10% test. Điểm quan trọng là toàn bộ track và window sinh ra từ cùng một video luôn nằm trong cùng một tập. Cách chia này tránh data leakage, tức tránh trường hợp mô hình thấy các cửa sổ rất giống nhau ở cả train và validation/test.


4.4.2 Diễn tiến huấn luyện (*Loss & Accuracy*)

Quá trình huấn luyện cho thấy mô hình hội tụ tương đối ổn định sau các epoch đầu và đạt trạng thái ổn định hơn ở giai đoạn sau. Trong các epoch đầu, Warmup Scheduler giúp learning rate tăng dần từ mức nhỏ lên learning rate ban đầu, từ đó hạn chế dao động mạnh và nguy cơ gradient explosion ở giai đoạn đầu huấn luyện.

Sau giai đoạn warmup, Cosine Annealing Warm Restarts điều chỉnh learning rate theo chu kỳ cosine. Cơ chế này giúp quá trình tối ưu có thêm cơ hội thoát khỏi local minimum và tiếp tục tìm nghiệm tốt hơn. Bên cạnh đó, Focal Loss, MixUp, Label Smoothing, Dropout và Early Stopping góp phần giảm overfitting khi bộ dữ liệu vẫn còn giới hạn về quy mô.



Đồ thị 2. Đường cong Loss trên tập huấn luyện và tập kiểm định theo epoch



Đồ thị 3. Đường cong Accuracy trên tập huấn luyện và tập kiểm định theo epoch


4.4.3 Đánh giá trên tập Validation

Bảng 15 trình bày kết quả đánh giá mô hình trên tập validation. Accuracy tổng thể đạt **0.90**. Đối với lớp Violence, Recall đạt **0.88**, cho thấy mô hình phát hiện được phần lớn các mẫu bạo lực trong tập kiểm định. Đây là chỉ số quan trọng trong bối cảnh an ninh

trường học vì hệ thống cần hạn chế bỏ sót tình huống nguy hiểm.

Bảng 15: Kết quả đánh giá mô hình trên tập Validation

Class	Precision	Recall	F1-Score	Support
Non-Violence	0.93	0.91	0.92	4222
Violence	0.86	0.88	0.87	2528
Accuracy tổng		0.90		6750
Macro avg	0.89	0.90	0.90	6750
Weighted avg	0.90	0.90	0.90	6750



Đồ thị 4. Heatmap ma trận nhầm lẫn trên tập Validation

4.4.4 Đánh giá trên tập Test


Ngoài tập validation, hệ thống được đánh giá thêm trên tập test độc lập. Đây là các video không xuất hiện trong quá trình huấn luyện và không được dùng để lựa chọn siêu tham số. Đánh giá trên tập test giúp phản ánh khách quan hơn khả năng tổng quát hóa của mô hình khi gặp dữ liệu mới.

Trong giai đoạn kiểm thử, kết quả cuối cùng được tổng hợp ở cấp video thay vì chỉ dựa trên từng cửa sổ riêng lẻ. Mỗi track được kết luận dựa trên xác suất bạo lực và ngưỡng **0.45**; sau đó kết quả video-level được xác định bằng biến `max_violent_persons`. Video được đánh dấu bạo lực khi `max_violent_persons` ≥ 1 . Cách đánh giá này gần hơn với cách hệ thống được sử dụng trong thực tế.


Bảng 16: Kết quả đánh giá mô hình trên tập Test độc lập

Class	Precision	Recall	F1-Score	Support
Non-Violence	0.89	0.92	0.91	1928
Violence	0.88	0.83	0.85	1297
Accuracy tổng		0.89		3225


Trên tập test độc lập, hệ thống đạt Accuracy video-level khoảng **89%**. Kết quả này được tổng hợp trong Bảng 16 và minh họa thêm bằng ma trận nhầm lẫn ở Đồ thị 5. Việc kết quả test không chênh lệch quá lớn so với validation khoảng **90%** là tín hiệu tích cực, cho thấy mô hình giữ được hiệu suất tương đối ổn định trên dữ liệu chưa từng dùng để huấn luyện.



Đồ thị 5. Heatmap ma trận nhầm lẫn trên tập Test



Đồ thị 6. Phân phối xác suất bạo lực trên tập Validation



Đồ thị 7. Phân phối xác suất bạo lực trên tập Test

Đồ thị 6 và Đồ thị 7 cho thấy phân phối xác suất $P(violence)$ của hai lớp có xu hướng tách biệt tương đối rõ. Phần lớn mẫu non-violence tập trung ở vùng xác suất thấp, trong khi nhiều mẫu violence nằm ở vùng xác suất cao hơn. Điều này cho thấy mô hình không chỉ dự đoán nhãn cuối cùng mà còn học được mức độ tin cậy phù hợp giữa hai nhóm hành vi.

Tuy nhiên, hai phân phối vẫn có một vùng chồng lấn ở quanh ngưỡng quyết định. Đây là khu vực dễ phát sinh False Positive và False Negative, thường tương ứng với các hành vi có chuyển động mạnh nhưng không bạo lực hoặc các tình huống bạo lực diễn ra gần, xa camera, bị che khuất. Vì vậy, việc sử dụng ngưỡng track-level 0.45 kết hợp với tổng hợp video-level bằng `max_violent_persons` là cần thiết để cân bằng giữa Recall và số lượng cảnh báo nhầm.

So sánh giữa validation và test, hình dạng phân phối nhìn chung vẫn giữ xu hướng tương tự. Điều này phù hợp với kết quả Accuracy trên test khoảng **89%**, cho thấy mô

hình có khả năng tổng quát hóa tương đối ổn định trên dữ liệu chưa dùng trong huấn luyện. Dù vậy, vùng chồng lấn giữa hai lớp cũng cho thấy hệ thống vẫn cần thêm dữ liệu đa dạng hơn và cơ chế mô hình hóa tương tác nhiều người để cải thiện các trường hợp khó.

4.4.5 So sánh với các kiến trúc khác (Ablation Study)

Để đánh giá đóng góp của từng thành phần trong kiến trúc đề xuất, đề tài thực hiện so sánh với một số biến thể baseline. Mục tiêu của ablation study không chỉ là tìm mô hình có chỉ số cao hơn, mà còn kiểm tra vai trò của Bi-LSTM, Attention và Multi-scale Temporal Conv1D trong bài toán phát hiện bạo lực từ chuỗi track người.

Bảng 17: So sánh hiệu quả với các kiến trúc tham khảo

Kiến trúc	Val Acc	Ghi chú
CNN + Simple LSTM (baseline)	~82%	Không Bi-LSTM, không Attention, không Multi-scale Conv1D
CNN + Bi-LSTM	~86%	Thêm ngữ cảnh hai chiều, cải thiện khoảng 4%
CNN + Bi-LSTM + Attention	~88%	Attention giúp tập trung vào thời điểm quan trọng
3D CNN (C3D-like)	~84%	Mô hình nặng, cần nhiều tài nguyên hơn
ImprovedViolenceModel (đề xuất)	89%	Multi-scale Conv1D + Bi-LSTM + Attention

Kết quả so sánh cho thấy Bi-LSTM giúp mô hình khai thác ngữ cảnh trước và sau hành vi, phù hợp với các tình huống bạo lực có diễn tiến ngắn nhưng cần quan sát chuỗi chuyển động. Attention tiếp tục cải thiện kết quả nhờ tập trung vào những timestep có dấu hiệu bất thường rõ hơn. Multi-scale Temporal Conv1D là thành phần quan trọng vì giúp bắt chuyển động ở nhiều tỉ lệ thời gian khác nhau, từ các va chạm nhanh đến các hành vi kéo dài hơn.

4.4.6 Thảo luận kết quả

Kiến trúc đề xuất đạt hiệu quả tốt hơn các baseline vì kết hợp được nhiều nhóm đặc trưng bổ trợ cho nhau. Spatial CNN trích xuất đặc trưng không gian từ từng crop người. Multi-scale Temporal Conv1D học các mẫu chuyển động ngắn hạn ở nhiều kích thước

kernel. Bi-LSTM bổ sung ngữ cảnh hai chiều cho toàn bộ chuỗi, còn Temporal Attention giúp mô hình tập trung vào các khoảnh khắc có khả năng chứa hành vi bạo lực.

Tuy nhiên, kết quả vẫn cần được nhìn nhận thận trọng. Một số trường hợp False Positive xuất hiện khi hành vi không bạo lực có chuyển động nhanh hoặc mạnh, chẳng hạn chạy đua, nhảy múa, chơi thể thao tiếp xúc hoặc vật lộn đùa nghịch. Các hành vi này có motion pattern gần giống bạo lực nên dễ bị mô hình cảnh báo nhầm nếu chỉ quan sát một track trong thời gian ngắn; đây cũng là khó khăn thường được nhắc đến trong các tổng quan gần đây về phát hiện bạo lực bằng thị giác máy tính [1, 2].

Các trường hợp False Negative thường xảy ra khi bạo lực diễn ra ở xa camera, bounding box quá nhỏ, hình ảnh bị mờ, hành vi kéo dài dưới 30 frame hoặc track bị gián đoạn do che khuất. Khi chuỗi đầu vào không đủ dài hoặc chất lượng tracking kém, mô hình không có đủ thông tin để nhận diện chính xác.

Một hạn chế quan trọng của kiến trúc hiện tại là phân tích từng track tương đối độc lập. Cách này giúp giảm nhiễu từ toàn cảnh, nhưng chưa trực tiếp mô hình hóa quan hệ nhân quả giữa các đối tượng, ví dụ người A vung tay và người B ngã. Quyết định video-level dựa trên `max_violent_persons` có thể cảnh báo khi xuất hiện ít nhất một track bạo lực, nhưng chưa thay thế được mô hình tương tác không gian–thời gian giữa nhiều người.

So với các công trình sử dụng 3D CNN nặng, hướng tiếp cận của đề tài nhẹ hơn và phù hợp hơn với mục tiêu tích hợp vào pipeline SafeWatch App. Tuy nhiên, do bộ dữ liệu trường học có bối cảnh phức tạp, nhiều người và điều kiện camera không đồng nhất, kết quả hiện tại nên được xem là bước thử nghiệm khả thi ban đầu thay vì kết luận cuối cùng về khả năng triển khai rộng rãi.

KẾT LUẬN

Tóm tắt kết quả đạt được

Sau quá trình thực hiện, đề án đã hoàn thành mục tiêu đề ra là xây dựng một hệ thống phát hiện hành vi bạo lực trong trường học dựa trên Deep Learning. Hệ thống không chỉ dừng ở mức huấn luyện mô hình phân loại, mà được tổ chức thành một pipeline tương đối hoàn chỉnh, có khả năng tiếp nhận video đầu vào, phát hiện và theo dõi người, tiền xử lý dữ liệu, phân loại hành vi và tổng hợp kết quả để hỗ trợ cảnh báo.

Về mặt quy trình, đề tài đã xây dựng pipeline end-to-end gồm năm bước chính: thu thập dữ liệu, tiền xử lý và chuẩn hóa dữ liệu, phát hiện đối tượng và trích xuất đặc trưng, phân loại hành vi bạo lực/bình thường, cuối cùng là phát hiện và cảnh báo theo thời gian gần thực. Cách tổ chức này giúp hệ thống có cấu trúc rõ ràng, dễ kiểm thử và có thể mở rộng từng thành phần trong các phiên bản sau.

Về mặt dữ liệu, đề tài đã xây dựng bộ dữ liệu gồm **389 video**, trong đó có **189 video bạo lực** và **200 video không bạo lực**. Dữ liệu được tổng hợp từ năm bộ dataset công khai và một phần video tự thu thập, sau đó được chọn lọc, gán nhãn và kiểm tra theo hướng phục vụ bài toán phát hiện bạo lực học đường. Bộ dữ liệu có annotation theo chuẩn CVAT và phù hợp hơn với phạm vi đề tài so với việc chỉ sử dụng nguyên trạng một bộ dữ liệu công khai tổng quát.

Về mặt mô hình, đề tài đã đề xuất kiến trúc **ImprovedViolenceModel**, kết hợp **Spatial CNN**, **Multi-scale Temporal Conv1D**, **Bi-LSTM** và **Temporal Attention**. Kiến trúc này khai thác đồng thời đặc trưng không gian, chuyển động đa tỉ lệ, ngữ cảnh thời gian hai chiều và cơ chế chú ý theo timestep. Mô hình có quy mô khoảng **2.8 triệu tham số**, kích thước file khoảng **8 MB**, nhẹ hơn nhiều so với các kiến trúc video lớn như 3D CNN hoặc Transformer.

Kết quả thực nghiệm cho thấy mô hình đạt Accuracy khoảng **90%** trên tập validation và Accuracy video-level khoảng **89%** trên tập test độc lập. Ở cấp video, hệ thống sử dụng biến `max_violent_persons` và kết luận có bạo lực khi `max_violent_persons` ≥ 1 . Đây là kết quả tích cực trong phạm vi bộ dữ liệu tự xây dựng và cho thấy hướng tiếp cận per-track classification kết hợp temporal modeling là khả thi đối với bài toán phát hiện bạo lực học đường.

Bên cạnh mô hình, đề tài cũng xây dựng hướng ứng dụng **SafeWatch App** với backend FastAPI và frontend Flutter Web. Ứng dụng hỗ trợ các chức năng như upload video, hàng chờ xử lý, dashboard, lịch sử phân tích, cấu hình hệ thống và cảnh báo qua email/Telegram. Nhờ đó, pipeline AI được đặt trong một hệ thống có giao diện thao tác và khả năng kiểm chứng trực quan.

Một đóng góp quan trọng khác là cơ chế quyết định đa tầng. Thay vì kết luận trực tiếp từ một window đơn lẻ, hệ thống tổng hợp kết quả ở cấp track với ngưỡng 45%, sau đó

tổng hợp ở cấp video với ngưỡng 70%. Cơ chế này giúp giảm tác động của các dự đoán nhiễu và hỗ trợ hạn chế báo động giả.

Tổng thể, đề tài đã giải quyết được nhiều khoảng trống nghiên cứu đã xác định ở Chương 2, gồm phân tích theo từng track người, mô hình hóa thời gian đa tỉ lệ, thiết kế mô hình nhẹ hơn, kết hợp YOLO tracking với Bi-LSTM và Attention, cũng như cơ chế quyết định đa tầng. Đồng thời, đề tài đóng góp thêm bộ dữ liệu phù hợp hơn với bối cảnh trường học.

Hạn chế

Mặc dù đã đạt được các kết quả nhất định, hệ thống vẫn còn một số hạn chế cần được nhìn nhận rõ ràng.

Thứ nhất, hạn chế về dữ liệu. Bộ dữ liệu 389 video vẫn còn tương đối nhỏ nếu so với các bộ dữ liệu lớn như RWF-2000 hoặc XD-Violence. Số lượng video này phù hợp để xây dựng và kiểm thử pipeline trong phạm vi đồ án tốt nghiệp, nhưng chưa đủ để bao quát mọi tình huống trong môi trường trường học thực tế. Các điều kiện như ánh sáng yếu, camera đặt cao, cảnh đông người, đồng phục giống nhau hoặc video chất lượng thấp vẫn cần được bổ sung thêm.

Ngoài ra, nhãn dữ liệu hiện chủ yếu ở cấp video. Khi sử dụng Sliding Window, một số cửa sổ trong video bạo lực có thể không thật sự chứa hành vi bạo lực nhưng vẫn nhận nhãn bạo lực. Đây là vấn đề weak label, có thể gây nhiễu trong quá trình huấn luyện. Bộ dữ liệu cũng chưa có nhóm riêng cho các hành vi dễ nhầm như đùa giỡn mạnh, chen lấn, chạy nhảy hoặc chơi thể thao tiếp xúc.

Thứ hai, hạn chế về kiến trúc. Hệ thống hiện phân tích từng track người tương đối độc lập. Cách này giúp giảm nhiễu từ toàn cảnh, nhưng chưa mô hình hóa trực tiếp quan hệ tương tác giữa nhiều người. Ví dụ, mô hình có thể thấy một người vung tay và một người khác ngã, nhưng chưa thật sự học được quan hệ nhân quả giữa hai hành động đó.

Bài toán hiện cũng được giới hạn ở phân loại nhị phân gồm bạo lực và không bạo lực. Hệ thống chưa phân biệt các dạng bạo lực cụ thể như đánh nhau, xô đẩy, đuổi đánh hoặc bắt nạt. Bên cạnh đó, yêu cầu track đủ 30 frame có thể làm hệ thống bỏ qua các hành vi diễn ra quá nhanh hoặc các track bị gián đoạn do che khuất.

Thứ ba, hạn chế về triển khai. Phiên bản hiện tại chủ yếu xử lý video đã quay sẵn hoặc video được upload qua ứng dụng. Hệ thống chưa hỗ trợ đầy đủ xử lý real-time streaming từ camera RTSP. Backend cũng chưa được thiết kế tối ưu cho nhiều camera đồng thời ở quy mô lớn, chẳng hạn thông qua hàng đợi phân tán hoặc xử lý song song nhiều worker.

Vấn đề bảo mật và quyền riêng tư cũng cần tiếp tục hoàn thiện. Video trường học có thể chứa hình ảnh nhận dạng được học sinh và giáo viên. Phiên bản hiện tại chưa áp dụng đầy đủ các cơ chế như làm mờ khuôn mặt trước khi lưu/gửi clip cảnh báo, mã hóa

HTTPS/SSL cho toàn bộ API, phân quyền người dùng chi tiết và chính sách tự động xóa video sau một khoảng thời gian nhất định.

Hướng phát triển tương lai

Từ các hạn chế trên, đề tài đề xuất một số hướng phát triển trong tương lai.

Về dữ liệu, cần mở rộng bộ dữ liệu lên quy mô lớn hơn, hướng đến 1000 video hoặc nhiều hơn. Dữ liệu nên được thu thập từ nhiều trường học, nhiều góc camera, nhiều điều kiện ánh sáng và nhiều mật độ học sinh khác nhau. Đặc biệt, cần bổ sung thêm các video thuộc nhóm dễ nhầm như đùa giỡn mạnh, chạy nhảy, va chạm nhẹ hoặc chơi thể thao để giúp mô hình giảm False Positive.

Một hướng quan trọng khác là bổ sung annotation ở cấp frame hoặc cấp đoạn thời gian. Khi biết chính xác hành vi bạo lực xảy ra ở khoảng frame nào, mô hình sẽ học đúng vị trí sự kiện hơn và giảm ảnh hưởng của weak label trong Sliding Window. Điều này cũng giúp việc đánh giá mô hình chi tiết và công bằng hơn.

Về kiến trúc mô hình, có thể nghiên cứu bổ sung luồng chuyển động như Optical Flow hoặc frame difference để tăng khả năng phân biệt giữa bạo lực thật và hành vi có chuyển động mạnh nhưng không nguy hiểm. Tuy nhiên, cần cân nhắc chi phí tính toán để không làm mất lợi thế nhẹ của pipeline hiện tại.

Ngoài ra, hướng multi-person interaction modeling cần được ưu tiên. Các mô hình graph-based, attention giữa các track hoặc đặc trưng tương tác theo cặp người có thể giúp hệ thống hiểu tốt hơn quan hệ giữa người tấn công, nạn nhân và các đối tượng xung quanh. Khi dữ liệu đủ lớn hơn, có thể thử nghiệm các kiến trúc lightweight Transformer như MobileViT hoặc EfficientViT, đồng thời mở rộng bài toán từ phân loại nhị phân sang phân loại đa lớp.

Một hướng mở rộng khác là nghiên cứu dữ liệu đa cảm biến trong các bối cảnh cần bảo vệ quyền riêng tư, ví dụ kết hợp camera với tín hiệu không hình ảnh hoặc cảm biến môi trường. Các khảo sát gần đây về phát hiện bạo lực bằng Wi-Fi và 5G/6G sensing cho thấy hướng này có tiềm năng bổ sung cho hệ thống camera truyền thống, dù vẫn cần cân nhắc chi phí triển khai và độ phù hợp với trường học [17].

Về triển khai hệ thống, cần tích hợp xử lý RTSP stream để hệ thống có thể làm việc trực tiếp với camera an ninh theo thời gian thực. Backend có thể được mở rộng bằng hàng đợi tác vụ như Celery và Redis để xử lý nhiều camera hoặc nhiều video đồng thời. Với yêu cầu triển khai tại chỗ, có thể nghiên cứu đưa mô hình lên thiết bị biên như NVIDIA Jetson Nano hoặc các thiết bị edge computing tương tự.

Về bảo mật và quyền riêng tư, hệ thống cần bổ sung face blurring trước khi lưu hoặc gửi clip cảnh báo, áp dụng HTTPS/SSL cho API và Flutter Web, phân quyền người dùng, ghi log truy cập và thiết lập chính sách tự động xóa video sau khi phân tích xong. Đây là điều kiện cần nếu muốn triển khai trong môi trường trường học thực tế.

Tóm lại, đề tài đã chứng minh tính khả thi của hướng phát hiện bạo lực học đường bằng video giám sát sử dụng Deep Learning. Kết quả hiện tại là nền tảng ban đầu để tiếp tục mở rộng dữ liệu, cải tiến mô hình, tối ưu triển khai và hoàn thiện các yêu cầu an toàn, bảo mật trong các phiên bản tiếp theo.

TÀI LIỆU

- [1] F. U. M. Ullah, M. S. Obaidat, A. Ullah, K. Muhammad, M. Hijji, and S. W. Baik, “A comprehensive review on vision-based violence detection in surveillance videos,” *ACM Computing Surveys*, vol. 55, no. 10, pp. 1–44, 2023.
- [2] P. Negre-Rodríguez *et al.*, “Literature review of deep-learning-based detection of violence in video,” *Sensors*, vol. 24, no. 12, p. 4016, 2024.
- [3] E. Nievas *et al.*, “Violence detection in video using computer vision techniques,” *CAIP*, 2011.
- [4] S. Sudhakaran and O. Lanz, “Learning to detect violent videos using convolutional and lstm networks,” *AVSS*, 2017.
- [5] M. Chang *et al.*, “Video violence recognition and localization using a semi-supervised hard attention model,” *Expert Systems with Applications*, vol. 212, p. 118791, 2023.
- [6] Y. Li *et al.*, “Violence-yolo: Enhanced gelan algorithm for violence detection,” *Applied Sciences*, vol. 14, no. 15, p. 6712, 2024.
- [7] F. Primero Primero *et al.*, “Utilizing deep learning models to develop a human school violence detection system,” *Symmetry*, 2025.
- [8] J. Redmon *et al.*, “You only look once: Unified, real-time object detection,” *CVPR*, 2016.
- [9] G. Jocher *et al.*, “Ultralytics yolo,” <https://github.com/ultralytics/ultralytics>, 2023, accessed: 2026.
- [10] Y. Zhang *et al.*, “Bytetrack: Multi-object tracking by associating every detection box,” *ECCV*, 2022.
- [11] G. Bertasius, H. Wang, and L. Torresani, “Is space-time attention all you need for video understanding?” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2021.
- [12] H. Fan, B. Xiong, K. Mangalam, Y. Li, Z. Yan, J. Malik, and C. Feichtenhofer, “Multiscale vision transformers,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 6824–6835.
- [13] A. Arnab, M. Dehghani, G. Heigold, C. Sun, M. Lučić, and C. Schmid, “Vivit: A video vision transformer,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021, pp. 6836–6846.

- [14] Z. Liu, J. Ning, Y. Cao, Y. Wei, Z. Zhang, S. Lin, and H. Hu, “Video swin transformer,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 3202–3211.
- [15] C. Li, X. Yang, and G. Liang, “Keyframe-guided video swin transformer with multi-path excitation for violence detection,” *The Computer Journal*, vol. 66, no. 5, pp. 1826–1837, 2023.
- [16] A. Vaswani *et al.*, “Attention is all you need,” *NeurIPS*, 2017.
- [17] A. Kannan and A. Z. Kouzani, “Violence detection using wi-fi and 5g/6g sensing technologies: A review,” *Electronics*, vol. 13, no. 14, p. 2765, 2024.
- [18] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [19] H. Zhang *et al.*, “mixup: Beyond empirical risk minimization,” *ICLR*, 2018.
- [20] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” *ICLR*, 2019.
- [21] A. Paszke *et al.*, “Pytorch: An imperative style, high-performance deep learning library,” *NeurIPS*, 2019.
- [22] G. Bradski, “The opencv library,” *Dr. Dobb’s Journal of Software Tools*, 2000.
- [23] V. H. Nguyễn, C. P. Tạ, T. L. Lê, Q. K. Ngô, and T. N. Trần, “C-vidnet: A model for supporting violence detection in schools,” *Ho Chi Minh City University of Education Journal of Science*, vol. 22, no. 5, pp. 801–813, 2025.
- [24] L. Q. Thao *et al.*, “An innovative solution to prevent school fighting violence,” *Journal of Intelligent & Fuzzy Systems*, 2023.
- [25] N. tác giả PTIT, “Multistage real-time violence detection using convolutional neural network and long short-term memory,” <https://trithuc.ptit.edu.vn/domestic-articles/2652>, 2023.